

VNIVERSITAT DE VALÈNCIA

Trabajo Fin de Grado - Curso 2024/ 2025

Modelos estadísticos de tipo self-exciting

Autor: **Marc Valero Ferrer**

Tutor: Álvaro Briz Redón
Gabriel Calvo Bayarri

Facultat de Ciències Matemàtiques

Grau en Matemàtiques

Índice general

1. Introducción **4**

2. Preliminares **6**
2.1. Distribución de Poisson. 6
2.2. Distribución Exponencial. 8
2.2.1. Distribución de Erlang. 9

3. Proceso de Poisson **11**
3.1. El Proceso de Poisson Homogéneo o Estacionario. 11
3.1.1. Definición y propiedades básicas. 11
3.1.2. Distribución de los tiempos entre eventos. 13
3.1.3. La paradoja del tiempo de espera. 13
3.1.4. Función de supervivencia. 16
3.1.5. Función de verosimilitud. 18
3.1.6. Distribuciones condicionales. 20
3.2. Proceso de Poisson Inhomogéneo o No Estacionario. 21
3.2.1. Definición e interpretación de la intensidad. 21
3.2.2. Función de verosimilitud. 22
3.2.3. Distribuciones condicionales. 23
3.2.4. Transformación a proceso estacionario. 24

4. Proceso Puntual Self-Exciting **25**
4.1. Introducción. 25
4.2. Modelos autoexcitantes espacio-temporales. 25
4.3. Modelo Marcado. 26
4.4. Log-Verosimilitud. 27
4.5. Aplicaciones. 28
4.5.1. Modelos de secuencia de réplicas sísmicas. 28
4.5.2. Predicción de crimen. 29
4.5.3. Predicción epidemiológica. 30
4.5.4. Redes Sociales. 31

5. Aplicación: El Modelo Autoexcitante Temporal para el Análisis de Datos de Baloncesto **33**
5.1. Implementación en R. 34
5.1.1. Cribado de los datos. 34
5.1.2. Aproximación numérica de la integral. 35
5.1.3. Estimación de los parámetros del modelo. 37
5.1.4. Evaluación del modelo. 38
5.2. Resultados Principales. 39
5.2.1. Estimación partido a partido. 39
5.2.2. Estimación conjunta sobre los partidos destacados. 43
5.2.3. Estimación conjunta sobre todos los partidos de la temporada. 44
5.3. Intervalos de Confianza para los Parámetros del Modelo. 45
5.3.1. Intervalos por partido. 45
5.3.2. Intervalos en conjunto de partidos. 47

6. Conclusiones **48**

7. Apéndice **50**
7.1. Códigos para la estimación por máxima verosimilitud. 50
7.2. Comparación de parámetros estimados por jugador en partidos representativos. 54

Capítulo 1

Introducción

En muchas situaciones reales, es habitual encontrarse con secuencias de eventos que no siguen un patrón completamente aleatorio. A menudo, la aparición de un suceso parece aumentar la probabilidad de que otros ocurran poco después. Este tipo de dinámica se ha observado en campos muy diversos como la sismología, donde los terremotos suelen ir seguidos de réplicas; en criminología, donde ciertos delitos tienden a repetirse en el mismo entorno; en epidemiología, donde un contagio puede desencadenar nuevos casos; o en redes sociales, donde un mensaje puede desencadenar múltiples respuestas. Todos estos casos comparten una característica común: cada evento tiene la capacidad de influir en los que le siguen.

En el deporte, y especialmente en el baloncesto, también puede observarse este tipo de patrones. Se conocen como rachas ofensivas, y hacen referencia a momentos en los que un jugador o equipo encadena varias anotaciones en un corto periodo de tiempo. Son parte fundamental del análisis del juego. Por ello, en este trabajo se analiza si realmente existe una base estadística que respalde esta percepción, y si anotar una canasta incrementa la probabilidad de encestar otra poco después. Este fenómeno ha sido ampliamente discutido en la literatura, especialmente a raíz del trabajo Gilovich et al. (1985), quienes concluyeron que el efecto *hot hand* era una ilusión. Sin embargo, estudios posteriores como el de Sun and Wang (2012) han argumentado que dicha conclusión puede depender del supuesto de estacionariedad, y que bajo ciertos enfoques estadísticos sí podrían detectarse patrones de racha.

Más allá del caso concreto del baloncesto, la estadística aplicada ha tenido un papel creciente en el análisis deportivo. Se ha empleado para evaluar el rendimiento individual y colectivo, desarrollar modelos predictivos y apoyar la toma de decisiones estratégicas Albert et al. (2017). Esta evolución ha dado lugar al campo conocido como *sports analytics*, que ha ganado relevancia en deportes como fútbol, béisbol o tenis, entre otros.

Con el fin de entender mejor los patrones de juego, se propone el uso de modelos autoexcitantes, una clase de procesos estocásticos capaces de recoger dependencias espacio-temporales entre eventos. En concreto, se estudiarán las anotaciones de dos y tres puntos de los Chicago Bulls durante la temporada 2022-2023, considerando cada canasta como un evento dentro de una secuencia temporal. El objetivo es comprobar si este modelo puede detectar, de forma objetiva, la presencia de rachas en el juego.

El trabajo se estructura en un total de siete capítulos. Tras la introducción inicial, el Capítulo 2 presenta los conceptos preliminares necesarios. En el Capítulo 3 se introduce el proceso de Poisson, que servirá como punto de partida para modelos posteriores. El Capítulo 4 expone el modelo autoexcitante, que permite capturar dependencias espacio-temporales entre eventos. A continuación, en el Capítulo 5 se aplica la versión temporal de dicho modelo a los datos de los Chicago Bulls, con el objetivo de analizar estadísticamente la existencia de rachas ofensivas. Finalmente, se presentan una serie de conclusiones y posibles líneas de mejora. Además, se incluye un apéndice con resultados del análisis que completan y refuerzan los estudios realizados en el Capítulo 5.

Capítulo 2

Preliminares

Vamos a comenzar con una revisión de algunas distribuciones de probabilidad que son especialmente útiles para nuestro trabajo. Estas distribuciones nos ayudarán a entender mejor el comportamiento de ciertos fenómenos aleatorios.

2.1. Distribución de Poisson.

Durante la Segunda Guerra Mundial, Londres fue objeto de intensos bombardeos. Para analizar si los ataques seguían un patrón aleatorio o si ciertas zonas eran objetivos prioritarios, los analistas británicos dividieron la ciudad en sectores de igual tamaño y registraron el número de impactos en cada uno (Kulkarni, 2011).

Supongamos que lanzan n bombas sobre la ciudad y que cada bomba tiene una probabilidad p de impactar en un sector determinado. Sea X el número de impactos en un sector dado. Como cada bomba cae independientemente de las demás, la variable aleatoria X sigue una distribución binomial de parámetros n y p:

$$Pr\{X = x\} = \binom{n}{x} p^x (1-p)^{n-x}, \quad 0 \leq x \leq n.$$

Sin embargo, calcular esta distribución para valores grandes de n no es tarea sencilla, ya que el término $\binom{n}{x}$ crece rápidamente, mientras que el producto $p^x(1-p)^{n-x}$ decrece considerablemente. Para simplificar esta expresión, vamos a estudiar el límite de la distribución binomial cuando $n \to +\infty$ y $p \to 0$ de forma que $np \approx \lambda \in (0, \infty)$ fijo. Si denotamos esta región límite como D obtenemos que:

$$\lim_D \binom{n}{x} p^x (1-p)^{n-x} = \lim_D \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} = \lim_D \frac{n(n-1)(n-2)\cdots(n-x+1)}{x!} p^x (1-p)^{n-x} =$$

$$= \lim_D \frac{n^x (1-\frac{1}{n})(1-\frac{2}{n})\cdots(1-\frac{x-1}{n})}{x!} p^x (1-p)^{n-x} = \lim_D \frac{(np)^x}{x!} \left(\prod_{r=0}^{x} \left(1 - \frac{r}{n}\right) \right) (1-p)^{n-x} =$$

$$= \lim_D \frac{(np)^x}{x!} \left(\prod_{r=0}^{x} \left(1 - \frac{r}{n}\right) \right) \left(1 - \frac{np}{n}\right)^{n-x} = \lim_D \frac{(np)^x}{x!} \left(\prod_{r=0}^{x} \left(1 - \frac{r}{n}\right) \right) \left(1 - \frac{np}{n}\right)^{n} (1-p)^{-x} =$$

$$= \lim_D \frac{(np)^x}{x!} \left(\lim_D \prod_{r=0}^{x} \left(1 - \frac{r}{n}\right) \right) \lim_D \left(1 - \frac{np}{n}\right)^{n} \lim_D (1-p)^{-x} = \left(\frac{\lambda^x}{x!}\right)(1)(e^{-\lambda})(1) = \frac{e^{-\lambda}\lambda^x}{x!}.$$

Hemos utilizado que:

$$\lim_D \left(1 - \frac{np}{n}\right)^n = \lim_{n\to\infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}.$$

Esta aproximación muestra cómo, bajo ciertas condiciones, la distribución binomial converge de forma natural a una nueva distribución, que definimos a continuación:

Definición 2.1. *Se dice que una variable aleatoria X sigue una distribución Poisson con parámetro λ si su función de probabilidad viene dada por:*

$$f_X(x) = \frac{\lambda^x}{x!} e^{-\lambda}, \quad si\ x = 0, 1, 2, ... \tag{2.1}$$

y cero en el resto de valores de x.

La función de distribución tiene por expresión:

$$F_X(x) = \sum_{n \le x} \frac{\lambda^n}{n!} e^{-\lambda}. \tag{2.2}$$

En este caso, decimos que X es una variable Poisson de parámetro λ y lo denotamos por:

$$X \sim Po(\lambda).$$

Notemos que (2.1) es una función de probabilidad. Esto se debe a que es no negativa y además:

$$\sum_{x=0}^{\infty} e^{-\lambda} \frac{\lambda^x}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} e^{\lambda} = 1.$$

Supongamos $X \sim Po(\lambda)$. Entonces, se cumple que:

$$E(X) = \sum_{x=0}^{\infty} x \cdot f_X(x) = \sum_{x=0}^{\infty} x \cdot \frac{\lambda^x e^{-\lambda}}{x!} = \sum_{x=1}^{\infty} \frac{\lambda^x e^{-\lambda}}{(x-1)!}$$

Sea $j = x - 1$. Luego, cuando $x = 1$, $j = 0$; y cuando $x \to \infty$, $j \to \infty$:

$$E(X) = \sum_{j=0}^{\infty} \frac{\lambda^{j+1} e^{-\lambda}}{j!} = \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda e^{-\lambda} \cdot e^{\lambda} = \lambda.$$

Además,

$$E(X(X-1)) = \sum_{x=0}^{\infty} x(x-1) e^{-\lambda} \frac{\lambda^x}{x!} = \lambda^2 e^{-\lambda} \sum_{x=2}^{\infty} \frac{\lambda^{x-2}}{(x-2)!} = \lambda^2.$$

De aquí,

$$V(X) = E(X^2) - (E(X))^2 = E(X(X-1)) - E(X) - (E(X))^2 = \lambda^2 + \lambda - \lambda^2 = \lambda.$$

Por tanto, si $X \sim Po(\lambda)$, se cumple que:

$$E(X) = \lambda = V(X). \tag{2.3}$$

2.2. Distribución Exponencial.

Si consideramos un proceso de desintegración radioactiva con una tasa de λ desintegraciones por unidad de tiempo, entonces el número de desintegraciones que se producen en el intervalo $[0, t]$ sigue una distribución de Poisson con parámetro λt, es decir:

$$N_t \sim Po(\lambda t).$$

Por otro lado, el tiempo que transcurre entre dos desintegraciones consecutivas es:

$$X \sim Exp(\lambda).$$

La distribución exponencial aparece en problemas relacionados con tiempos de espera y está relacionada con la distribución Poisson de igual parámetro. Mientras que la Poisson cuenta el número de eventos que ocurren en un intervalo de tiempo, la exponencial modela el tiempo entre dichos eventos.

Definición 2.2. *Se dice que la variable aleatoria X sigue una distribución exponencial con parámetro λ si su función de densidad viene dada por:*

$$f_X(x) = \lambda e^{-\lambda x}, \quad si\ x \geq 0. \tag{2.4}$$

y 0 en el resto de valores de x.

La función de distribución tiene por expresión:

$$F_X(x) = 1 - e^{-\lambda x}, \quad x \geq 0. \tag{2.5}$$

En este caso, decimos que X es una variable exponencial de parámetro λ y lo denotamos por:

$$X \sim Exp(\lambda).$$

Supongamos $X \sim Exp(\lambda)$. Entonces, se cumple que:

$$E(X) = \int_0^\infty x \cdot \lambda e^{-\lambda x}\, dx \underset{\text{Integración por partes}}{=} \left[-xe^{-\lambda x}\right]_0^\infty + \int_0^\infty e^{-\lambda x}\, dx = \frac{1}{\lambda}.$$

Notemos que,

$$E(X^2) = \int_0^\infty x^2 \cdot \lambda e^{-\lambda x}\, dx = \frac{2}{\lambda^2}.$$

Entonces,

$$V(X) = E(X^2) - (E(X))^2 = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2}.$$

Por tanto, si $X \sim Exp(\lambda)$, se cumple que:

$$E(X) = \frac{1}{\lambda}. \tag{2.6}$$

$$V(X) = \frac{1}{\lambda^2}. \tag{2.7}$$

2.2.1. Distribución de Erlang.

Definición 2.3. *Se dice que la variable aleatoria X sigue una distribución Erlang con parámetros k y λ si su función de densidad es:*

$$f_X(x) = \lambda e^{-\lambda x} \frac{(\lambda x)^{k-1}}{(k-1)!}, \quad k = 1, 2, 3, \ldots, \quad \wedge \quad x \geq 0. \tag{2.8}$$

y 0 en el resto de valores de k y x.

La función de distribución viene dada por:

$$F_X(x) = 1 - \sum_{r=0}^{k-1} \frac{(\lambda x)^r}{r!}, \quad x \geq 0. \tag{2.9}$$

Propiedad 2.2.1. (Suma de exponenciales). *Supongamos que X_i, con $i = 1, 2, \ldots, n$ son idd variables aleatorias exponenciales con parámetro λ. Consideremos:*

$$Z_n = X_1 + X_2 + \cdots + X_n.$$

Entonces, $Z_n \sim Erl(n, \lambda)$.

Demostración. Vamos a probarlo por inducción sobre $n \in \mathbb{N}$.

Para $n = 1$, se cumple que:

$$Z_1 \sim Exp(\lambda) = Erl(1, \lambda).$$

Ahora, supongamos que el resultado es cierto para $n = k$. Veamos que $Z_{k+1} = Z_k + X_{k+1} \sim Erl(k+1, \lambda)$.
Por la independencia de Z_k y X_{k+1} deducimos que:

$$f_{Z_{k+1}}(z) = \int_0^z f_{Z_k}(x) f_{X_{k+1}}(z-x)\,dx = \int_0^z \frac{\lambda^k x^{k-1} e^{-\lambda x}}{(k-1)!} \cdot \lambda e^{-\lambda(z-x)}\,dx = \frac{\lambda^{k+1} e^{-\lambda z}}{(k-1)!} \int_0^z x^{k-1}\,dx$$
$$= \frac{\lambda^{k+1} z^k e^{-\lambda z}}{k!}.$$

Entonces,

$$f_{Z_{k+1}}(z) \sim Erl(k+1, \lambda).$$

Por tanto, por inducción, se concluye que:

$$Z_n = \sum_{i=1}^{n} X_i \sim Erl(n, \lambda), \quad \text{para todo } n \in \mathbb{N}.$$

□

Capítulo 3

Proceso de Poisson

En muchos sistemas reales, los eventos se producen de forma aislada a lo largo del tiempo. Esto sucede, por ejemplo, con las llegadas de personas a una cola, los terremotos o las reclamaciones en una aseguradora. Para modelar este tipo de fenómenos, se recurre a los procesos puntuales, que asignan puntos aleatoriamente sobre un intervalo de la recta real. Entre ellos, el Proceso de Poisson es fundamental (Daley and Vere-Jones, 2006).

3.1. El Proceso de Poisson Homogéneo o Estacionario.

3.1.1. Definición y propiedades básicas.

Supongamos que queremos modelizar la ocurrencia de eventos a lo largo del tiempo. Para ello, trabajamos sobre la recta real, dividiéndola en una sucesión de intervalos semiabiertos de la forma $(a_i, b_i]$, donde $a_i < b_i \leq a_{i+1}$.

Denotamos por $N(a_i, b_i]$ al número de eventos que ocurren en cada intervalo, es decir, la cantidad de puntos del proceso que caen dentro del intervalo $(a_i, b_i]$. Por ejemplo:

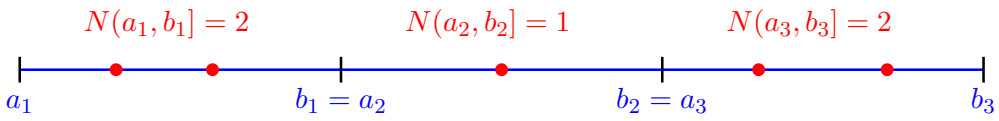


Figura 3.1: Conteo de eventos de un proceso de Poisson homogéneo en intervalos disjuntos.

Definición 3.1. *Se llama proceso de Poisson homogéneo o estacionario al proceso estocástico* $\{N(a_i, b_i], \quad a_i < b_i \leq a_{i+1}\}$ *definido por:*

$$Pr\{N(a_i, b_i] = n_i,\ i = 1, ..., k\} = \prod_{i=1}^{k} \frac{(\lambda(b_i - a_i))^{n_i}}{n_i!} e^{-\lambda(b_i - a_i)}. \tag{3.1}$$

Lo denotamos PP(λ).

De hecho, esta definición considera tres aspectos importantes:

1. El número de puntos en cada intervalo finito $(a_i, b_i]$ sigue una distribución Poisson con parámetro $\lambda(b_i - a_i)$, es decir $N(a_i, b_i] = n_i \sim Po(\lambda(b_i - a_i)), \quad i = 1, ..., k$.
2. El número de puntos en intervalos disjuntos es independiente y aleatorio.
3. Las distribuciones son estacionarias: solo dependen de las longitudes $b_i - a_i$ de los intervalos.

$$\int_{a_i}^{b_i} \lambda \, dx = \lambda(b_i - a_i) \quad \text{donde } \lambda \text{ no depende de } x. \tag{3.2}$$

Por tanto, la distribución conjunta puede verse como un caso particular de la distribución Poisson multivariante en el que las variables son independientes. De este modo, para cualquier intervalo semiabierto $(a, b]$ se tendrá que:

$$E(N(a, b]) = \lambda(b - a) = V(N(a, b]), \tag{3.3}$$

donde,

- $E(N(a, b])$ es la *esperanza* del número de eventos que caen en el intervalo $(a, b]$.
- $V(N(a, b])$ es la *varianza* del número de eventos que caen en el intervalo $(a, b]$.
- λ es la *intensidad* del proceso. También se puede interpretar como la *tasa media* o *densidad media* del proceso puntual.

Dado que la esperanza y la varianza son iguales y proporcionales a la longitud del intervalo podemos plantear un test de diagnóstico para verificar si un proceso puntual sigue un proceso de Poisson estacionario. Para ello, se puede estimar $E(N(a, b])$ y $V(N(a, b])$ en distintos intervalos semiabiertos $(a, b]$ de diversas longitudes y representar los cocientes:

$$\frac{V(N(a, b])}{b - a}.$$

Si se trata de un proceso de Poisson estacionario estos valores deben ser aproximadamente constantes e iguales a la intensidad λ. De esta forma, cualquier desviación significativa de esta constancia indicaría una desviación de la suposición de Poisson o una falta de estacionariedad en el proceso.

3.1.2. Distribución de los tiempos entre eventos.

Sea t_k el tiempo en el que ocurre el k-ésimo evento. Supongamos $t_0 = 0$ y definimos:

$$T_k = t_k - t_{k-1}, \quad k \geq 1. \tag{3.4}$$

Así, T_k representa el tiempo transcurrido entre el k-ésimo y el $(k-1)$-ésimo evento. A continuación estudiaremos la distribución de T_k para $k \geq 1$, es decir, la distribución del tiempo transcurrido entre dos eventos consecutivos cualquiera.

Para ello, sea $N(0, \tau]$ el número de eventos que ocurren durante el intervalo $(0, \tau]$. A partir de la definición (3.1), observamos lo siguiente:

$$Pr\{T_1 > \tau\} = Pr\{N(0, \tau] = 0\} = e^{-\lambda\tau}, \qquad \text{donde} \quad T_1 = t_1 - t_0, \tag{3.5}$$

que representa la probabilidad de no encontrar puntos en un intervalo de longitud τ. Esta expresión también se puede interpretar como la probabilidad de que el intervalo aleatorio que va desde el origen hasta el primer punto que aparece a su derecha tenga longitud mayor que τ, es decir, la *función de supervivencia de la longitud del intervalo.*

Por tanto, queda probado que el tiempo transcurrido entre el primer evento y el origen sigue una distribución exponencial de parámetro λ, es decir, $T_1 \sim Exp(\lambda)$.

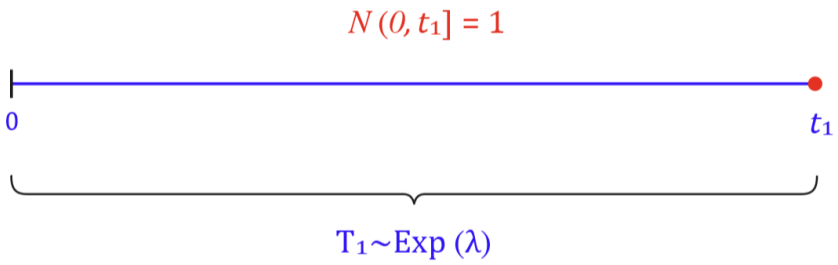


Figura 3.2: Estudio de la distribución de la longitud del intervalo entre eventos consecutivos.

3.1.3. La paradoja del tiempo de espera.

En un proceso de Poisson estacionario, resulta interesante analizar qué sucede si se observa el sistema desde un instante de tiempo elegido al azar, como puede ser el origen. En particular, queremos estudiar la longitud del intervalo en el que se encuentra dicho instante, es decir, el tiempo hasta el evento que aparezca inmediatamente a su derecha o izquierda. Estos intervalos son conocidos en la Teoría de Colas como la *recursividad hacia adelante* y la *recursividad hacia atrás.*

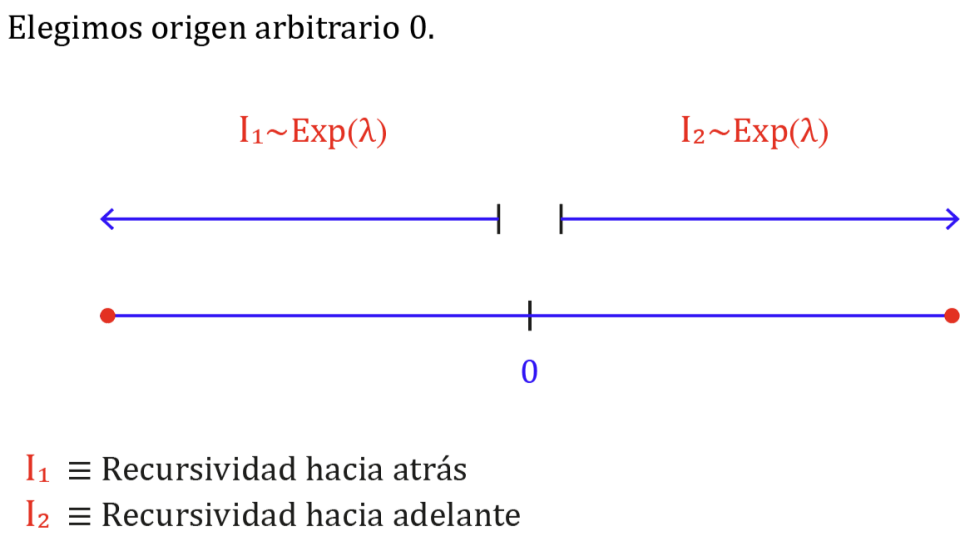


Figura 3.3: Estudio de las distribuciones de los intervalos de recursividad hacia atrás y hacia adelante.

Por tanto, para un PP(λ) la longitud de los intervalos de tiempo de recursividad hacia adelante y hacia atrás sigue una distribución exponencial de parámetro λ.

Gracias a la propiedad de independencia, podemos extender este resultado a la distribución del intervalo de tiempo entre cualesquiera par de puntos consecutivos del proceso. Dado un punto en el intervalo $(-\Delta, 0]$, se cumple que la distribución condicional del tiempo hasta el siguiente evento a la derecha del origen tiene siempre la misma forma exponencial, sin depender de Δ. Entonces, a medida que $\Delta \to 0$, se considera que la forma límite de esta distribución condicional es la misma distribución exponencial. De forma similar, al analizar las formas límite de distribuciones conjuntas más complejas, se puede demostrar que los intervalos sucesivos no solo siguen una distribución exponencial, sino que además son independientes.

Por último, queda por analizar el comportamiento del intervalo específico que contiene al origen. Aunque podría parecer intuitivo suponer que la longitud sigue una distribución exponencial (como los demás intervalos entre eventos consecutivos), esto no es correcto.

De hecho, el intervalo que contiene al origen es la suma de los tiempos de recursividad hacia adelante y hacia atrás, es decir, de dos variables exponenciales independientes. Por tanto, la longitud total del intervalo que contiene al origen sigue una distribución de Erlang con parámetros 2 y λ.

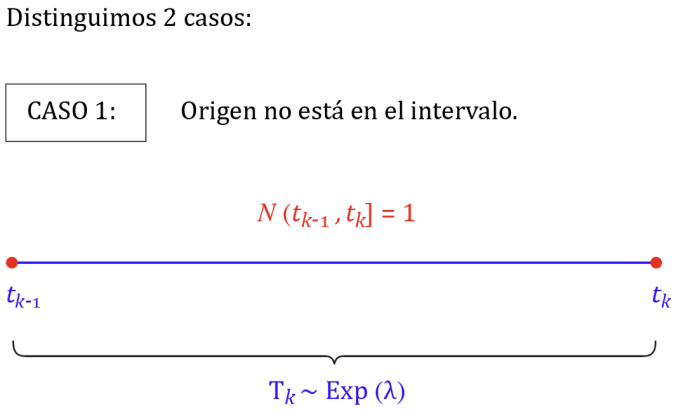


Figura 3.4: Estudio de la distribución de la longitud del intervalo que no contiene al origen.

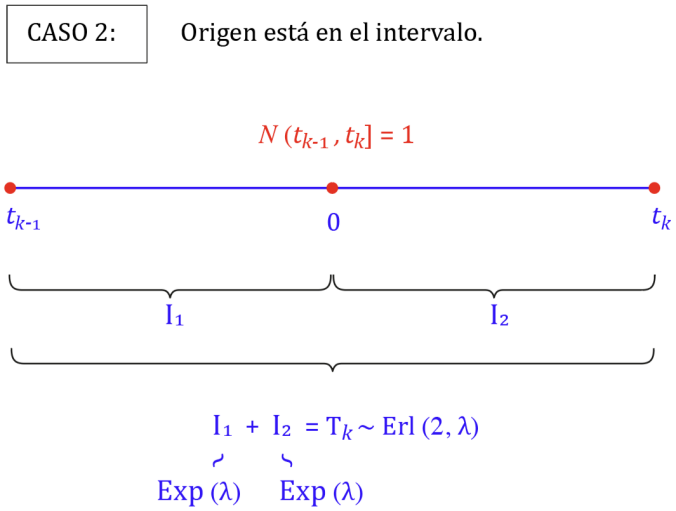


Figura 3.5: Estudio de la distribución de la longitud del intervalo que contiene al origen.

Este resultado se conoce como la "Paradoja del tiempo de Espera", ya que describe el dilema de un pasajero que llega a una parada de autobús en la que el servicio de buses sigue un patrón de llegadas de tipo Poisson.

La paradoja del tiempo de espera ocurre en procesos como el de Poisson y describe cómo, a pesar de que los eventos se distribuyen de forma uniforme en promedio a lo largo del tiempo, el tiempo de espera promedio para el siguiente evento puede ser mayor que el esperado. Esto se debe a que la llegada del pasajero (posición del origen, aleatoria) no está relacionada con el proceso que gobierna la llegada de los autobuses. Como resultado, es más probable que el pasajero llegue durante un intervalo

largo entre buses, lo que hace que el tiempo de espera parezca mayor.

En otras palabras, es más probable encontrarse en medio de un intervalo largo porque ocupa "más espacio" en el tiempo.

En un proceso aleatorio, cada instante de tiempo tiene la misma probabilidad de ser elegido. Por ello, como los intervalos largos albergan más instantes posibles, aumentan las posibilidades de caer dentro de ellos. Es como lanzar un dado en una línea dividida en segmentos: los segmentos largos tienen más longitud, por lo que es más probable que el dado caiga en ellos.

3.1.4. Función de supervivencia.

Sea $t_k = t_k - t_0$, $k = 1, 2, ...$, el tiempo de espera desde el origen $t_0 = 0$ hasta el k-ésimo evento t_k.

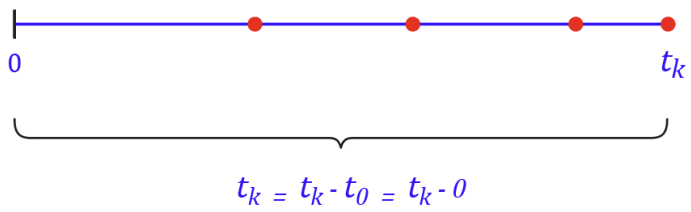


Figura 3.6: Tiempo de espera hasta el k-ésimo evento.

Entonces, tenemos que:

$$\{t_k > x\} = \{N(0, x] < k\}, \tag{3.6}$$

describe eventos idénticos donde,

- $\{t_k < x\}$: La longitud del intervalo que va desde el origen hasta el evento k-ésimo t_k es mayor que x.
- $\{N(0, x] < k\}$: El número de eventos en el intervalo semiabierto $N(0, x]$ es menor que k.

Por la primera propiedad derivada de la definición (3.1) sabemos que $N(0, x] \sim Po(\lambda x)$. Esto quiere decir que:

$$Pr\{N(0, x] = j\} = \frac{(\lambda x)^j}{j!} e^{-\lambda x}.$$

Por tanto, la probabilidad de la derecha en (3.6) es:

$$Pr\{t_k > x\} = P\{N(0,x] < k\} = \sum_{j=0}^{k-1} Pr\{N(0,x] = j\} = \sum_{j=0}^{k-1} \frac{(\lambda x)^j}{j!} e^{-\lambda x} = \left(1 + \sum_{j=1}^{k-1} \frac{(\lambda x)^j}{j!}\right) e^{-\lambda x}. \tag{3.7}$$

Derivamos para obtener la función de densidad:

$$\frac{d}{dx}\left[\left(1 + \sum_{j=1}^{k-1} \frac{(\lambda x)^j}{j!}\right) e^{-\lambda x}\right] = \frac{d}{dx}\left(e^{-\lambda x}\right) + \sum_{j=1}^{k-1} \frac{d}{dx}\left(\frac{(\lambda x)^j}{j!} e^{-\lambda x}\right).$$

Además,

$$\frac{d}{dx}\left(\frac{(\lambda x)^j}{j!} e^{-\lambda x}\right) = \frac{d}{dx}\left(\frac{(\lambda x)^j}{j!}\right) e^{-\lambda x} + \frac{(\lambda x)^j}{j!} \frac{d}{dx}\left(e^{-\lambda x}\right).$$

Luego,

$$\frac{d}{dx}\left(\frac{(\lambda x)^j}{j!}\right) = \frac{j\lambda(\lambda x)^{j-1}}{j!} = \frac{\lambda^j x^{j-1}}{(j-1)!},$$

$$\frac{d}{dx}\left(e^{-\lambda x}\right) = -\lambda e^{-\lambda x}.$$

Entonces,

$$\frac{d}{dx}\left(\frac{(\lambda x)^j}{j!} e^{-\lambda x}\right) = \left(\frac{\lambda^j x^{j-1}}{(j-1)!} - \frac{\lambda^{j+1} x^j}{j!}\right) e^{-\lambda x}.$$

Observamos que,

$$-\lambda e^{-\lambda x} + \sum_{j=1}^{k-1} \left(\left(\frac{\lambda^j x^{j-1}}{(j-1)!} - \frac{\lambda^{j+1} x^j}{j!}\right) e^{-\lambda x}\right) = e^{-\lambda x}\left(-\lambda + \sum_{j=1}^{k-1} \left(\frac{\lambda^j x^{j-1}}{(j-1)!} - \frac{\lambda^{j+1} x^j}{j!}\right)\right) = -\frac{\lambda^k x^{k-1}}{(k-1)!} e^{-\lambda x}.$$

Por tanto, obtenemos que la *función de supervivencia* para el k-ésimo evento s_k es:

$$f_k(x) = \frac{\lambda^k x^{k-1}}{(k-1)!} e^{-\lambda x}. \tag{3.8}$$

Se trata, de nuevo, de una distribución de Erlang. Notemos que el tiempo hasta el k-ésimo evento, t_k, se puede considerar como la suma de las longitudes de k intervalos aleatorios $(t_0, t_1], (t_1, t_2], ..., (t_{k-1}, t_k]$ que son independientes y exponencialmente distribuidos. En efecto, esto no es más que otra prueba de que la suma de k variables aleatorias exponenciales independientes tiene una distribución de Erlang (2.2.1).

3.1.5. Función de verosimilitud.

La *verosimilitud* de una realización finita de un proceso de Poisson puede expresarse como el producto de dos factores:

- La probabilidad de observar un número determinado de eventos en el intervalo considerado.
- La densidad condicional conjunta de los tiempos en los que ocurren dichos eventos, es decir, dada la cantidad total de eventos, cómo se distribuyen dichos sucesos dentro del intervalo.

Por tanto, para calcular la verosimilitud en un intervalo de tiempo dado, es necesario conocer tanto el número de eventos ocurridos como su distribución temporal.

Supongamos que hay M eventos en el intervalo $(0, T]$ situados en los puntos temporales $t_1, ..., t_M$.

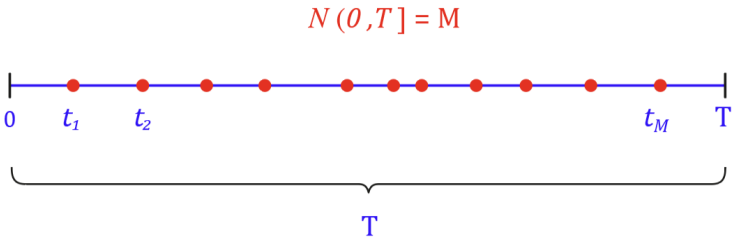


Figura 3.7: Realización de un proceso de Poisson homogéneo con M eventos en el intervalo $(0, T]$.

Por la definición (3.1) podemos obtener la probabilidad de solo obtener un evento en un subintervalo de la forma $(t_k - \Delta, t_k]$:

$$Pr\{N(t_k - \Delta, t_k] = 1\} = \frac{\lambda(t_k - (t_k - \Delta))}{1!} e^{-\lambda(t_k - (t_k - \Delta))} = \lambda \Delta e^{-\lambda \Delta}. \tag{3.9}$$

Entonces, como el proceso es estacionario $(*)$, la probabilidad de que ocurra un único evento en cada subintervalo de la forma $(t_k - \Delta, t_k]$ es:

$$\prod_{k=1}^{M} Pr\{N(t_k - \Delta, t_k] = 1\} = \left(\prod_{k=1}^{M} \lambda \Delta \right) e^{-\lambda M \Delta} \overset{(*)}{=} (\lambda \Delta)^M e^{-\lambda M \Delta}. \tag{3.10}$$

Por otro lado, la probabilidad de que no haya eventos en el resto del intervalo $(0, T]$ se corresponde al producto de tres probabilidades:

- La probabilidad de que no haya eventos en el subintervalo $(0, t_1 - \Delta]$:

$$Pr\{N(0, t_1 - \Delta] = 0\} = e^{-\lambda(t_1 - \Delta)}.$$

- La probabilidad de que no haya eventos en el subintervalo $(s_M, T]$:

$$Pr\{N(t_M, T] = 0\} = e^{-\lambda(T-t_M)}.$$

- La probabilidad de que no haya eventos entre los subintervalos de la forma $(t_k, t_{k+1} - \Delta]$:

$$Pr\left\{N\left(\bigcup_{k=1}^{M-1}(t_k, t_{k+1} - \Delta]\right) = 0\right\} = \prod_{k=1}^{M-1} e^{-\lambda(t_{k+1}-\Delta-t_k)}.$$

Luego,

$$Pr\left\{N\left((0,T] \setminus \bigcup_{k=1}^{M}(t_k - \Delta, t_k]\right) = 0\right\} = e^{-\lambda(t_1-\Delta)} \cdot e^{-\lambda(T-t_M)} \cdot \prod_{k=1}^{M-1} e^{-\lambda(t_{k+1}-\Delta-t_k)} = e^{-\lambda(T-\Delta M)}. \tag{3.11}$$

En consecuencia, la probabilidad de que ocurra exactamente un evento en cada subintervalo de la forma $(t_k - \Delta, t_k]$ para $k = 1, ..., M$, y ningún evento en el resto del intervalo $(0, T]$, es el producto:

$$Pr\left\{N\left((0,T] \setminus \bigcup_{k=1}^{M}(t_k - \Delta, t_k]\right) = 0\right\} \cdot \left(\prod_{k=1}^{M} Pr\{N(t_k - \Delta, t_k] = 1\}\right) = \left(\prod_{k=1}^{M} \lambda\Delta\right) e^{-\lambda T} \overset{(*)}{=} (\lambda\Delta)^M e^{-\lambda T}. \tag{3.12}$$

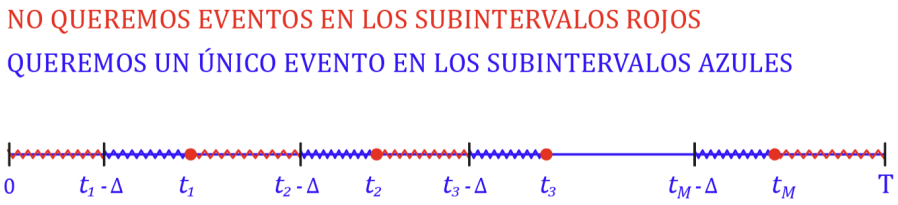


Figura 3.8: Eventos distribuidos exactamente en subintervalos $(t_k - \Delta, t_k]$.

Dividiendo entre Δ^M y haciendo que $\Delta \to 0$ obtenemos que, para un proceso de Poisson estacionario, la *función de verosimilitud* viene dada por:

$$L_{(0,T]}(M; t_1, ..., t_M) = \lambda^M e^{-\lambda T}. \tag{3.13}$$

Esta representa cuán probable es observar M eventos en $(0, T]$ que ocurren exactamente en los puntos temporales $t_1, ..., t_M$.

3.1.6. Distribuciones condicionales.

Supongamos que se han observado M eventos en el intervalo $(0, T]$. En este contexto, resulta interesante analizar cómo se distribuyen temporalmente dentro del intervalo. Según la definición (3.1), la probabilidad de observar exactamente M eventos en $(0, T]$ es:

$$Pr\{N(0,T] = M\} = \frac{(\lambda T)^M}{M!} e^{-\lambda T}. \tag{3.14}$$

Dado que se conocen los tiempos exactos $(t_1, ..., t_M)$ en los que ocurrieron los eventos, la probabilidad de que se sitúen precisamente en esos puntos, condicionada al número total de eventos, viene dada por:

$$Pr\{(t_1, ..., t_M)|N(0,T] = M)\} = \frac{Pr\big\{\big((t_1, ..., t_M), N(0,T] = M\big)\big\}}{Pr\{N(0,T] = M\}} = \frac{\lambda^M e^{-\lambda T}}{\frac{(\lambda T)^M}{M!} e^{-\lambda T}} = \frac{M!}{T^M}. \tag{3.15}$$

De hecho, se corresponde a una distribución uniforme en "$[0, T]$".

Conviene destacar un aspecto importante de este resultado: estamos tratando los eventos como si fuesen *indistinguibles*, salvo por su posición en el tiempo. Sin embargo, en contextos físicos, puede ser interesante que las M partículas sí sean distinguibles. En este caso, el factor $M!$ puede interpretarse como el número de formas distintas de asignar las M partículas a los M instantes temporales observados.

Desde esta perspectiva, debemos entender que las partículas están distribuidas de forma uniforme e independiente sobre el intervalo $(0, T]$. Se dice que las distribuciones condicionales del proceso de Poisson son equivalentes a las que se obtendrían al disponer M partículas indistinguibles de forma uniforme al azar sobre el $(0, T]$.

En efecto, gracias a la propiedad de independencia asociada a la definición (3.1) obtenemos que:

$$Pr\{N(0,x] = k|N(0,T] = M\} = \frac{Pr\{N(0,x] = k, N(x,T] = M - k\}}{Pr\{N(0,T] = M\}}. \tag{3.16}$$

Además,

- $N(0, x] \sim Po(\lambda x)$.
- $N(x, T] \sim Po(\lambda(T - x))$.

Como son independientes, podemos utilizar que la densidad conjunta es el producto de las densidades marginales:

$$\begin{aligned} Pr\{N(0,x] = k, N(x,T] = M - k\} &= Pr\{N(0,x] = k\} \cdot Pr\{N(x,T] = M - k\} \\ = \frac{(\lambda x)^k}{k!} e^{-\lambda x} \cdot \frac{(\lambda(T-x))^{M-k}}{(M-k)!} e^{-\lambda(T-x)} &= \frac{(\lambda x)^k}{k!} \cdot \frac{(\lambda(T-x))^{M-k}}{(M-k)!} \cdot e^{-\lambda T}. \end{aligned}$$

Por otro lado,

$$Pr\{N(0,T] = M\} = \frac{(\lambda T)^M}{M!} e^{-\lambda T}.$$

Sustituimos en (3.24) y obtenemos que:

$$Pr\{N(x,T] = k | N(0,T] = M\} = \frac{Pr\{N(0,x] = k, N(x,T] = M-k\}}{Pr\{N(0,T] = M\}} = \frac{\frac{(\lambda x)^k}{k!} \cdot \frac{(\lambda(T-x))^{M-k}}{(M-k)!} \cdot \cancel{e^{-\lambda T}}}{\frac{(\lambda T)^M}{M!} \cancel{e^{-\lambda T}}} =$$

$$= \frac{(\lambda x)^k (\lambda(T-x))^{M-k} \cdot M!}{k!(M-k)!(\lambda T)^M} = \frac{(\cancel{\lambda^k} x^k) \cdot (\cancel{\lambda^{M-k}} \cdot (T-x)^{M-k}) \cdot M!}{k!(M-k)!(\cancel{\lambda^M} T^M)} = \frac{M!}{k!(M-k)!} \cdot \frac{x^k (T-x)^{M-k}}{T^M} =$$

$$= \binom{M}{k} \left(\frac{x}{T}\right)^k \left(\frac{T-x}{T}\right)^{M-k} = \binom{M}{k} \left(\frac{x}{T}\right)^k \left(1 - \frac{x}{T}\right)^{M-k}. \tag{3.17}$$

Por tanto, hemos probado que la distribución condicional de $N(0,x]$, dado que hay M eventos en total en $(0,T]$, es una distribución Binomial con parámetros M y $\frac{x}{T}$. En resumen, los M eventos se distribuyen uniformemente e independientemente sobre $(0,T]$, y la probabilidad de que un evento caiga en $(0,x]$ es $\frac{x}{T}$.

3.2. Proceso de Poisson Inhomogéneo o No Estacionario.

3.2.1. Definición e interpretación de la intensidad.

Formalmente, el proceso de Poisson inhomogéneo, también conocido como proceso de Poisson no estacionario, se define de forma análoga al caso homogéneo (3.1), pero considerando que la intensidad del proceso varía con el tiempo, es decir, $\lambda(t)$.

Definición 3.2. *Se llama proceso de Poisson inhomogéneo o no estacionario al proceso estocástico* $\{N(a_i,b_i], \quad a_i < b_i \leq a_{i+1}\}$ *definido por:*

$$Pr\{N(a_i,b_i] = n_i,\ i = 1,...,k\} = \prod_{i=1}^{k} \frac{(\Lambda(a_i,b_i])^{n_i}}{n_i!} e^{-\Lambda(a_i,b_i]}. \tag{3.18}$$

Lo denotamos PP(Λ) *o PP*$(\lambda(t))$*.*

De hecho, esta definición considera tres aspectos importantes:

1. El número de puntos en cada intervalo finito $(a_i,b_i]$ sigue una distribución Poisson con parámetro $\Lambda(a_i,b_i]$, es decir $N(a_i,b_i] = n_i \sim Po(\Lambda(a_i,b_i]), \quad i = 1,...,k$.

2. El número de puntos en intervalos disjuntos es independiente y aleatorio.

3. Las distribuciones son no estacionarias: la intensidad del proceso varía con el tiempo.

$$\Lambda(a_i, b_i] = \int_{a_i}^{b_i} \lambda(t)\, dt. \tag{3.19}$$

En consecuencia, la probabilidad de que ocurran M eventos en el intervalo $(0, T]$ para un PP($\lambda(t)$) es:

$$Pr\{N(0,T] = M\} = \frac{(\Lambda(0,T])^M}{M!} e^{-\Lambda(0,T]}. \tag{3.20}$$

3.2.2. Función de verosimilitud.

En el caso no estacionario, la intensidad varía a lo largo del tiempo, por lo que los tiempos específicos de los eventos sí importan. De este modo, la probabilidad de que un evento ocurra en t_k es proporcional a $\lambda(t_k)$. Por tanto, la verosimilitud conjunta es:

$$L_{(0,T]}(M; t_1, ..., t_M) = \left(\prod_{k=1}^{M} \lambda(t_k) \right) e^{-\Lambda(0,T]}, \tag{3.21}$$

donde $\Lambda(0, T] = \int_0^T \lambda(t)dt$.

Notemos que

$$\prod_{k=1}^{M} \lambda(t_k) = \exp\left\{ \sum_{k=1}^{M} \log(\lambda(t_k)) \right\}.$$

Entonces,

$$L_{(0,T]}(M; t_1, ..., t_M) = \left(\prod_{k=1}^{M} \lambda(t_k) \right) e^{-\Lambda(0,T]} = \exp\left\{ \sum_{k=1}^{M} \log(\lambda(t_k)) - \int_0^T \lambda(t)dt \right\} =$$

$$= \exp\left\{ \int_0^T \log(\lambda(t)) M(dt) - \int_0^T \lambda(t)dt \right\}. \tag{3.22}$$

Aquí, el proceso puntual M es una medida aleatoria que cuenta el número de eventos en un intervalo infinitesimal dt. Es decir,

- Si hay un evento en t_k, entonces $M(dt_k) = 1$.
- Si no hay evento en t_k, entonces $M(dt) = 0$.

De esta forma, es evidente que:

$$\int_0^T \log(\lambda(s)) M(dt) = \sum_{k=1}^{M} \log(\lambda(t_k)).$$

3.2.3. Distribuciones condicionales.

Vamos a calcular las distribuciones condicionales para un PP($\lambda(t)$). Dados M eventos en el intervalo $(0,T]$, la probabilidad de que se sitúen en los puntos temporales $(t_1,...,t_M)$ es:

$$Pr\{\big((t_1,...,t_M)|N(0,T]=M\} = \frac{(Pr\{(t_1,...,t_M),N(0,T]=M\big)}{Pr\{N(0,T]=M\}} \overset{(3.15)}{=}$$

$$= \frac{\Big(\prod_{k=1}^{M}\lambda(t_k)\Big)\cancel{e^{-\Lambda(0,T]}}}{\frac{(\Lambda(0,T])^M}{M!}\cancel{e^{-\Lambda(0,T]}}} = M!\left(\prod_{k=1}^{M}\frac{\lambda(t_k)}{\Lambda(0,T]}\right). \tag{3.23}$$

Análogamente, en el caso no estacionario, gracias a la propiedad de independencia asociada a la definición (3.18) obtenemos que:

$$Pr\{N(0,x]=k|N(0,T]=M\} = \frac{Pr\{N(0,x]=k,N(x,T]=M-k\}}{Pr\{N(0,T]=M\}}. \tag{3.24}$$

Además,

- $N(0,x]\sim Po(\Lambda(0,x])$.
- $N(x,T]\sim Po(\Lambda(x,T])$.

Como son independientes, podemos utilizar que la densidad conjunta es el producto de las densidades marginales:

$$Pr\{N(0,x]=k,N(x,T]=M-k\} = Pr\{N(0,x]=k\}\cdot Pr\{N(x,T]=M-k\}$$
$$= \frac{(\Lambda(0,x])^k}{k!}e^{-\Lambda(0,x]}\cdot\frac{(\Lambda(x,T])^{M-k}}{(M-k)!}e^{-\Lambda(x,T]} = \frac{(\Lambda(0,x])^k}{k!}\cdot\frac{(\Lambda(x,T])^{M-k}}{(M-k)!}e^{-\Lambda(0,T]}.$$

Por otro lado,

$$Pr\{N(0,T]=M\} = \frac{(\Lambda(0,T])^M}{M!}e^{-\Lambda(0,T]}.$$

Sustituimos en (3.24) y obtenemos que:

$$Pr\{N(x,T]=k|N(0,T]=M\} = \frac{Pr\{N(0,x]=k,N(x,T]=M-k\}}{Pr\{N(0,T]=M\}} = \frac{\frac{(\Lambda(0,x])^k}{k!}\cdot\frac{(\Lambda(x,T])^{M-k}}{(M-k)!}\cancel{e^{-\Lambda(0,T]}}}{\frac{(\Lambda(0,T])^M}{M!}\cancel{e^{-\Lambda(0,T]}}} =$$

$$= \frac{M!}{k!(M-k)!}\cdot\left(\frac{\Lambda(0,x]}{\Lambda(0,T]}\right)^k\cdot\left(\frac{\Lambda(x,T]}{\Lambda(0,T]}\right)^{M-k} = \binom{M}{k}\cdot\left(\frac{\Lambda(0,x]}{\Lambda(0,T]}\right)^k\cdot\left(\frac{\Lambda(x,T]}{\Lambda(0,T]}\right)^{M-k}. \tag{3.25}$$

3.2.4. Transformación a proceso estacionario.

Consideremos el cambio de variable temporal:

$$\Phi : t \to u(t) = \Lambda(0, t]. \tag{3.26}$$

Denotemos $N(t) = N(0, T]$ para todo $t \geq 0$ y definamos el proceso puntual:

$$\widetilde{N}(t) = N(u^{-1}(t)). \tag{3.27}$$

Entonces, $\widetilde{N}(t)$ es un proceso de Poisson estacionario con intensidad $\widetilde{\Lambda}(0, T] = u(u^{-1}(t)) = t$, es decir, tiene tasa constante igual a 1. Por tanto, no hay duda de que los resultados del proceso de Poisson no estacionario pueden obtenerse a partir del caso estacionario mediante un cambio de variable.

Capítulo 4

Proceso Puntual Self-Exciting

4.1. Introducción.

El interés por modelar fenómenos en los que un evento incrementa la probabilidad de que ocurran otros poco después (ya sea en el tiempo, en el espacio o en ambos) ha crecido notablemente en los últimos años. Este tipo de comportamiento, donde los eventos se "contagian" o se "propagan", aparece en contextos muy diversos como la sismología para modelar terremotos y sus réplicas, la criminología para analizar la concentración de delitos en determinadas zonas y momentos, o la epidemiología para anticipar la evolución de enfermedades contagiosas.

Este tipo de dinámicas se puede modelizar mediante procesos puntuales autoexcitantes (*self-exciting point processes*), en los que la probabilidad de que ocurra un nuevo evento en un instante dado depende directamente de los eventos pasados. Esta dependencia se formaliza a través de una intensidad condicional, que permite cuantificar cómo el historial del proceso influye en su evolución temporal (Reinhart, 2018).

En este capítulo se parte de la versión más general de los modelos autoexcitantes: la formulación espacio-temporal. Aunque esta extensión permita capturar interacciones tanto en el tiempo como el espacio, más adelante nos centraremos únicamente en el componente temporal, que aplicaremos sobre un caso práctico. Además, se introducirán algunas variantes útiles del modelo, se construirá su log-verosimilitud y se repasarán sus distintas aplicaciones más recientes.

4.2. Modelos autoexcitantes espacio-temporales.

Los *modelos autoexcitantes espacio-temporales* son una extensión natural de los procesos Poisson. Se caracterizan por tener una intensidad condicional que se altera cada vez que ocurre un evento. De esta forma, queda reflejada la idea de que un suceso puede desencadenar o facilitar la aparición de otro después.

Estos modelos describen la probabilidad de que ocurra un evento en un punto del espacio $s \in X \subseteq \mathbb{R}^d$ y en un instante $t \in [0, T)$. Para ello, se utiliza una *intensidad condicional espacio-temporal*. Esta

función muestra el impacto de eventos pasados sobre los futuros sucesos, teniendo en cuenta dónde y cuándo ocurrieron. La fórmula general es:

$$\lambda(s,t|\mathcal{H}_t) = \mu(s) + \sum_{t_k<t} g(s-s_k, t-t_k), \tag{4.1}$$

donde,

- $\{s_1, s_2, \ldots, s_n\}$ es la secuencia observada de localizaciones de los eventos.
- $\{t_1, t_2, \ldots, t_n\}$ es la secuencia observada de tiempos de los eventos.
- $\mu(s)$ es la tasa de fondo (*background rate of events*).
- $g(\cdot)$ es la función de autoexcitación (*triggering function*).

Según la forma escogida para $g(\cdot)$, el proceso puede depender únicamente de la historia reciente, si g se disminuye rápido. En cambio, si g decae lentamente, el proceso puede conservar memoria a largo plazo y permitir que los eventos pasados sigan influyendo.

Nota 4.2.1. *Habitualmente, la función de autoexcitación g se asume no negativa y, para facilitar su tratamiento, suele considerarse separable en sus componentes espacial y temporal. Es decir, se expresa como:*

$$g(s-s_k, t-t_k) = f(s-s_k)h(t-t_k).$$

donde f describe la influencia espacial y h la influencia temporal del evento k-ésimo.

4.3. Modelo Marcado.

Un proceso puntual se considera *marcado* cuando, además del tiempo o la ubicación de los eventos, se observan características adicionales asociadas a cada uno de ellos. Por ejemplo, en el caso de los terremotos, se pueden considerar como procesos puntuales espacio-temporales de epicentro la localización y el tiempo. Sin embargo, esto deja fuera la magnitud. Esta variable adicional resulta especialmente relevante, pues tanto la cantidad como la distribución de las réplicas de un terremoto dependen en gran medida de ella.

Así, un proceso puntual marcado está compuesto por eventos de la forma $\{s_k, t_k, r_k\}$, donde:

- $s_k \in X \subseteq \mathbb{R}^d$ representa la localización espacial del k-ésimo evento.
- $t_k \in [0, T)$ es el instante temporal en el que ocurre el k-ésimo evento.
- $r_k \in \mathcal{R}$ es la marca, que toma valores en el espacio de marcas $\mathcal{R}$.

Nota 4.3.1. *Un caso particular es el proceso puntual multivariante, en el que el espacio de marcas es finito y discreto, es decir, $\mathcal{R} = \{1, \ldots, m\}$ para algún $m \in \mathbb{Z}$.*

Las marcas pueden presentar distintas propiedades:

1. Independientes: si dadas las localizaciones y los tiempos de los eventos $\{(s_k, t_k)\}$, las marcas r_k son independientes entre sí. Además, la distribución de cada marca depende únicamente del punto (s_k, t_k) donde ocurre el evento.

2. Impredecibles: si las marcas r_k son independientes de toda información previa del proceso, es decir, no dependen de las localizaciones, tiempos ni marcas de los eventos anteriores.

Un proceso puntual marcado tiene asociado un *proceso base* (*ground process*), que corresponde al proceso puntual de las localizaciones y los tiempos de los eventos, sin considerar las marcas asociadas. A partir de la *intensidad condicional del proceso base*, denotada por $\lambda_g(s, t|\mathcal{H}_t)$, se puede definir la *intensidad condicional del proceso marcado* como:

$$\lambda(s, t, r|\mathcal{H}_t) = \lambda_g(s, t|\mathcal{H}_t) f(r|s, t), \tag{4.2}$$

donde,

- $f(r|s, t)$ es la *densidad condicional de la marca* r en la localización s y el instante t, dado el historial del proceso hasta el momento t.

4.4. Log-Verosimilitud.

En la sección dedicada al proceso de Poisson inhomogéneo se dedujo que, si se conoce la intensidad condicional $\lambda(t)$, la función de verosimilitud asociada a una realización finita del proceso sobre un intervalo $(0, T]$, con eventos en los tiempos $\{t_1, \ldots, t_M\}$, viene dada por:

$$L_{(0,T]}(M; t_1, ..., t_M) = \left(\prod_{k=1}^{M} \lambda(t_k) \right) \exp\left(- \int_0^T \lambda(t) dt \right).$$

Esta estructura se mantiene en los modelos autoexcitantes, pero se sustituye la función de intensidad $\lambda(t)$ por la correspondiente intensidad condicional del modelo considerado. De esta forma, se incorpora explícitamente la dependencia del proceso respecto a su historial.

Partiendo entonces de la expresión general de la verosimilitud para procesos Poisson inhomogéneos, podemos deducir las expresiones de log-verosimilitud para los siguientes modelos espacio-temporales:

- Modelo no marcado: Los eventos se presentan como pares (s_k, t_k), donde $s_k \in X \subseteq \mathbb{R}^d$ y $t_k \in (0, T]$, para $k = 1, \ldots, M$.

$$l_{X\times(0,T]}((s_1, t_1), \ldots, (s_M, t_M)) = \left(\sum_{k=1}^{M} \log\left(\lambda(s_k, t_k|\mathcal{H}_{t_k})\right) \right) - \int_0^T \int_X \lambda(s, t|\mathcal{H}_t) ds\, dt. \tag{4.3}$$

- Modelo marcado: Cada evento es una terna (s_k, t_k, r_k), donde $r_k \in \mathcal{R}$ representa una característica adicional asociada al evento k-ésimo para $k = 1, \ldots, M$.

$$l_{X\times(0,T]\times\mathcal{R}}((s_1,t_1,r_1),\ldots,(s_M,t_M,r_M)) = \left(\sum_{k=1}^{M}\log\left(\lambda_g(s_k,t_k)\right)\right) + \left(\sum_{k=1}^{M}\log\left(f(r_k|s_k,t_k)\right)\right) - \int_0^T\int_X \lambda_g(s,t|\mathcal{H}_t)ds\,dt. \tag{4.4}$$

Estas expresiones, permiten cuantificar cuán probable es haber observado una secuencia de eventos concreta bajo un modelo dado. Esto resulta fundamental para la estimación de parámetros.

4.5. Aplicaciones.

Hasta este punto se ha desarrollado la teoría detrás de los modelos autoexcitantes, presentando su formulación matemática y las distintas variantes que permite adaptarlos a diferentes contextos. A continuación, se explicarán algunos casos concretos en los que los modelos autoexcitantes han resultado ser especialmente útiles para describir la aparición agrupada de eventos en el tiempo, el espacio o ambos.

4.5.1. Modelos de secuencia de réplicas sísmicas.

Una de las aplicaciones más consolidadas de los modelos autoexcitantes se encuentra en la sismología. En concreto, se utilizan para describir cómo un terremoto principal puede desencadenar réplicas tras su ocurrencia. Para ello, Ogata (1998) propuso el modelo ETAS (Epidemic-Typle Aftershock Sequence), una versión autoexcitante basada en la ley de Omori. En su formulación original, se trata de un modelo puramente temporal, cuya intensidad condicional es:

$$\lambda(t|\mathcal{H}_t) = \mu + \sum_{t_k\leq t}\frac{K_0 e^{\alpha(M_k-M_0)}}{(t-t_k+c)^p}, \tag{4.5}$$

donde,

- μ es la tasa de fondo constante.
- M_k es la magnitud del k-ésimo evento.
- M_0 es el umbral mínimo de magnitud para que un evento se incluya en el análisis.
- α es una constante que determina cuánto influye la magnitud del terremoto en su capacidad de generar réplicas.
- c y p son constantes que regulan el decaimiento temporal.

Posteriormente, este modelo fue extendido para incorporar también la dimensión espacial Zhuang et al. (2002), dando lugar a una versión espacio-temporal capaz de capturar la distribución geográfica de las réplicas. Esta extensión permite modelizar conjuntamente el momento y la localización de los eventos, proporcionando una descripción más completa del modelo sísmico.

4.5.2. Predicción de crimen.

Tras el desarrollo de los modelos ETAS en sismología, Mohler et al. (2011) propuso una analogía con la criminalidad, tratando ciertos delitos como eventos que pueden desarrollar "réplicas" cercanas en el espacio y tiempo. Estudios previos mostraban que crímenes como los robos en viviendas o los tiroteos suelen repetirse en las mismas zonas en cortos periodos de tiempo.

Esta dinámica motivó la aplicación de modelos autoexcitantes espacio-temporales. La intensidad condicional quedó definida de la siguiente forma:

$$\lambda(s,t|\mathcal{H}_t) = \nu(t)\mu(s) + \sum_{k;t_k<t} g(s-s_k, t-t_k), \tag{4.6}$$

donde,

- $\nu(t)$ recoge patrones temporales de fondo (clima o estación del año).
- $\mu(s)$ es la tasa de fondo espacial.
- $g(\cdot)$ es la función de autoexcitación espacio-temporal.

Dado el alto coste computacional, Mohler (2014) introduce una versión que permite además incorporar indicadores adelantados, como delitos menores que precedían a crímenes graves. En este modelo, se simplifica la intensidad suponiendo que $\nu(t) = 1$. Además, cada evento está marcado por su tipología y la tasa de fondo espacial viene dada por:

$$\mu(s) = \sum_{i=k}^{n} \frac{\alpha_{D_k}}{2\pi\eta^2 T} \exp\left(-\frac{||s-s_i||^2}{2\eta^2}\right), \tag{4.7}$$

donde,

- D_k marca que indica el tipo de delito.
- T es la longitud del intervalo de tiempo considerado.
- s_k es la localización del k-ésimo evento.
- α es un vector de pesos que determina la contribución de cada tipo de evento D_i.

Similarmente, la función de autoexcitación también es paramétrica y decae exponencialmente con el tiempo. Sea D un delito determinado, se define:

$$g(s,t,D) = \frac{\theta_M}{2\pi\omega\sigma^2} \exp\left(-\frac{t}{\omega}\right) \exp\left(-\frac{||s||^2}{2\sigma^2}\right), \tag{4.8}$$

donde,

- θ pondera la influencia de cada tipo de crimen.
- ω, σ determinan el alcance espacial y temporal de la autoexcitación.

4.5.3. Predicción epidemiológica.

Los procesos puntuales espacio-temporales autoexcitados se han aplicado con éxito en el ámbito de la epidemiología, especialmente en el análisis de la propagación de enfermedades infecciosas. Estos modelos permiten describir de forma explícita como un caso observado (por ejemplo, un contagio) incrementa la probabilidad de aparición de nuevos casos próximos en el espacio y el tiempo.

Uno de los primeros modelos aplicados a datos epidemiológicos fue propuesto por Meyer et al. (2012), en un estudio sobre la meningitis meningocócica invasiva (IMD). Distinguen entre dos tipos de contagio. Por un lado, aquellos que no guardan relación con casos anteriores, como si el contagio proviniera de una fuente externa no observada. Por otro lado, aquellos que se producen por transmisión directa entre individuos, es decir, cuando un caso observado desencadena uno nuevo en su entorno cercano.

Esta distinción se incorpora en el modelo a través de la siguiente expresión para la intensidad condicional:

$$\lambda(s,t|\mathcal{H}_t) = \rho(s,t)\exp\left(\beta' z(s,t)\right) + \sum_{j\in I^*(s,t)} e^{\eta_j} g(t-t_i) f(||s-s_j||), \tag{4.9}$$

donde,

- $\rho(s,t)$ es la densidad poblacional.
- $z(s,t)$ es un vector de covariables espacio-temporales.
- β' coeficientes del vector $z(s,t)$.
- e^{η_j} representa la capacidad del contagio del individuo j.
- $f(\cdot)$ y $g(\cdot)$ modelan la decaída temporal y espacial del contagio, respectivamente.
- $I^*(s,t)$ contiene los eventos pasados considerados capaces de desencadenar nuevos contagios en (s,t).

Este enfoque fue extendido por Schoenberg et al. (2019), quienes introdujeron una versión recursiva en la que la capacidad de contagio de cada caso depende de la intensidad local del proceso. De esta forma, se tiene en cuenta la saturación del entorno y la posible disminución de población susceptible. En este caso, la intensidad condicional toma la forma:

$$\lambda(s,t|\mathcal{H}_t) = \mu + \int\int H(\lambda(s',t'))g(s-s',t-t')dN(s',t'), \tag{4.10}$$

donde,

- $H(x) = \kappa x^{-\alpha}$ es el efecto de saturación. Permite que la capacidad de contagio disminuya cuando ya se han producido muchos casos en el entorno.
- $g(\cdot)$ es la función de autoexcitación espacio-temporal.

4.5.4. Redes Sociales.

En las redes sociales, es habitual que una acción realizada por un usuario, como enviar un mensaje o publicar contenido, provoque nuevas acciones por parte de otros usuarios conectados a él. Por este motivo, este tipo de situaciones se han modelado mediante procesos autoexcitantes, ya que permiten representar cómo un evento puede aumentar la probabilidad de que ocurran otros poco después dentro de la misma red.

Un ejemplo aparece en el estudio de los correos electrónicos entre oficiales de la academia militar de West Point (Fox et al., 2016). En este caso, cada oficial se representa como un nodo, y las conexiones se establecen en función de los mensajes intercambiados. Modelan la intensidad del nodo i (su tasa de envío de mensajes) como:

$$\lambda_i(t|\mathcal{H}_t) = \nu_i \mu(t) + \sum_j \sum_{k<t} \theta_{ij} \omega_i e^{-\omega_i (t - r_{ij}^k)}, \tag{4.11}$$

donde,

- r_{ij}^k es el momento en el que el usuario j envió su k-ésimo mensaje a i.
- ω_i controla la decaída temporal.
- θ_{ij} regula la tasa de respuesta de i hacia j.
- $\mu(t)$ modela los patrones de actividad que cambian a lo largo del día o la semana. Por ejemplo, las diferencias entre el día y la noche o entre los días de la semana y los fines de semana.

Por otro lado, Green et al. (2017) estudian la propagación de la violencia armada a través de redes sociales en Chicago. Cada nodo representa a un individuo arrestado, y se establecen conexiones entre sujetos que fueron arrestados juntos. De esta forma, consiguieron modelizar la probabilidad de que una persona sea víctima de un tiroteo como función de la actividad previa en su entorno social:

$$\lambda_k(t|\mathcal{H}_t) = \mu(t) + \sum_{t_i<t} \varphi_{ki}(t - t_i), \tag{4.12}$$

donde,

- $\mu(t)$ recoge variaciones estacionales.
- $\varphi_{ki}(t-t_i)$ función de autoexcitación. Se encarga de cuantificar la influencia de un evento anterior ocurrido en i sobre la probabilidad de que k experimente un evento en el instante t. Está definida por:

$$\varphi_{u,v}(t) = f_\beta(t) \cdot g_\alpha(u,v),$$

$$f_\beta(t) = \beta e^{-\beta t}, \quad g_\alpha(u,v) = \begin{cases} \alpha \cdot \text{dist } (u,v)^{-2}, & \text{si dist}(u,v) \leq 3, \\ 0, & \text{en otro caso,} \end{cases}$$

siendo $\text{dist}(u, v)$ la distancia geodésica entre los nodos u y v dentro de la red. Es decir, el número mínimo de conexiones necesarias para ir de un nodo a otro. Por ejemplo, si dos individuos están directamente conectados, la distancia es 1; pero, si se necesita pasar por un tercero para conectar u y v, entonces la distancia es 2. Esta cantidad se utiliza para modelar hasta qué punto la influencia de un evento disminuye a medida que se aleja del nodo donde ocurrió.

Capítulo 5

Aplicación: El Modelo Autoexcitante Temporal para el Análisis de Datos de Baloncesto

Aunque para aficionados, jugadores y medios de comunicación las rachas ofensivas son comunes en el baloncesto, algunos estudios han sostenido que no son más que una ilusión. El trabajo de Gilovich et al. (1985) abrió un debate todavía vigente sobre la existencia real del efecto *hot hand* y la posibilidad de detectarlo mediante herramientas estadísticas.

En este capítulo, se analizan las anotaciones de dos y tres puntos de los Chicago Bulls de la temporada 2022-2023, tratándolas como eventos en una secuencia temporal ordenada dentro del intervalo de duración del partido $(0, T]$. El objetivo es determinar si una canasta cambia la dinámica del juego, haciendo más probable que se anote otra poco después.

Para estudiar este caso, se propone un modelo autoexcitante de tipo temporal. En primer lugar, se presentará su formulación teórica. A continuación, se explicará el procedimiento de estimación de parámetros mediante máxima verosimilitud, así como su implementación en R. Posteriormente, se detallarán los criterios empleados para evaluar la calidad del ajuste. Finalmente, se aplicará el modelo tanto a nivel de equipo como individual.

En este contexto, la intensidad condicional representa la tasa esperada de anotaciones en un instante t, teniendo en cuenta el historial previo. Para incorporar el efecto autoexcitante, es decir, que una anotación pueda incrementar la probabilidad inmediata de otra, proponemos la siguiente formulación:

$$\lambda(t|\mathcal{H}_t) = \mu + \sum_{t_i<t} \theta \cdot e^{-\phi(t-t_i)}, \tag{5.1}$$

donde,

- μ es la tasa de fondo (sin considerar el historial).
- θ controla cuánto aumenta la intensidad tras cada canasta.

- ϕ regula la rapidez con la que el efecto de autoexcitación decae.

De ahora en adelante, el objetivo principal va a ser estimar los parámetros μ, θ, ϕ del modelo a partir de los datos observados. Para ello, se utiliza la función de log-verosimilitud. En el caso de un único partido con anotaciones en los tiempos $\{t_1, \ldots, t_M\}$ dentro del intervalo $(0, T]$, la log-verosimilitud viene dada por:

$$l(t|\mu, \theta, \phi) = \left(\sum_{i=1}^{M} \log \left(\lambda(t_i|\mathcal{H}_{t_i}) \right) \right) - \int_0^T \lambda(t|\mathcal{H}_t) dt. \tag{5.2}$$

Sin embargo, analizar partidos de forma individual puede resultar limitado, ya que el bajo número de eventos por partido podría afectar a la calidad de las estimaciones. Por ello, es interesante considerar varios partidos de forma conjunta, lo cual no solo incrementa la cantidad total de eventos observados, sino que también permite obtener estimaciones más estables y detectar patrones que podrían pasar desapercibidos en análisis aislados.

Para aprovechar toda la información disponible y obtener estimaciones más precisas, se construye una log-verosimilitud conjunta al sumar las contribuciones individuales de cada partido:

$$l(t|\mu, \theta, \phi) = \sum_{j=1}^{k} \left(\sum_{i=1}^{M_j} \log(\lambda_j(t_i|\mathcal{H}_{t_i})) - \int_0^{T_j} \lambda_j(t|\mathcal{H}_t) dt \right), \tag{5.3}$$

donde,

- M_j: número de eventos del partido $j \in \{1, .., k\}$.
- T_j: tiempo final del partido $j \in \{1, .., k\}$.
- k: número total de partidos considerados.

5.1. Implementación en R.

Con el modelo teórico ya definido, el objetivo ahora es implementarlo utilizando el lenguaje de programación R. Esta sección describe de forma detallada cada una de las fases implicadas. Para ello, se tratan cuestiones como la limpieza de la base de datos, el cálculo de la log-verosimilitud mediante métodos numéricos y las técnicas de optimización empleadas para la estimación de los parámetros del modelo.

5.1.1. Cribado de los datos.

Para poder aplicar el modelo de forma coherente, fue necesario realizar un cribado y transformación de los datos. De todas las jugadas registradas por los Chicago Bulls, se seleccionaron solo aquellas que terminaron en canasta, excluyendo los tiros libres.

Cada anotación se convirtió a una escala temporal continua de minutos desde el inicio del partido, teniendo en cuenta la estructura típica de la NBA (cuatro cuartos de 12 minutos y prórrogas de 5 minutos si las hubiera). Además, se registró el jugador responsable de cada anotación. El resultado fue una tabla como la siguiente:

match_id	**tiempo(minutos)**	**jugador**
⋮	⋮	⋮

Por tanto, del filtrado descrito se derivan dos conjuntos de datos:

- `CHI`: recoge la actividad anotadora total del equipo, excluyendo los tiros libres.
- `JUGADOR`: subconjunto de `CHI` filtrado por jugador, que incluye únicamente los partidos en los que dicho jugador anotó al menos dos veces. Incorpora una variable *contador*, que numera de forma consecutiva los partidos en los que el jugador realizó anotaciones válidas. En particular, este análisis se ha aplicado a los jugadores más anotadores del equipo: Zach LaVine, Coby White, Nikola Vucevic y DeMar DeRozan.

5.1.2. Aproximación numérica de la integral.

Como paso previo al análisis con datos reales, cabe preguntarse por el comportamiento de la intensidad condicional a lo largo del tiempo bajo nuestro modelo. ¿Qué forma tendría esta función para secuencias reales de anotaciones? ¿Cómo respondería ante una racha de canastas?

Para explorar visualmente esta idea en el contexto del equipo, tomemos como referencia el partido 59 de la base de datos y grafiquemos la evolución de la intensidad condicional asignando valores arbitrarios para los parámetros del modelo. Esto nos permitirá observar cómo varía dicha intensidad a lo largo del encuentro en función de las anotaciones registradas. En concreto, en la fig. 5.1 se aprecia cómo cada canasta provoca un incremento momentáneo en la intensidad, seguido de un descenso gradual los tramos sin anotaciones.

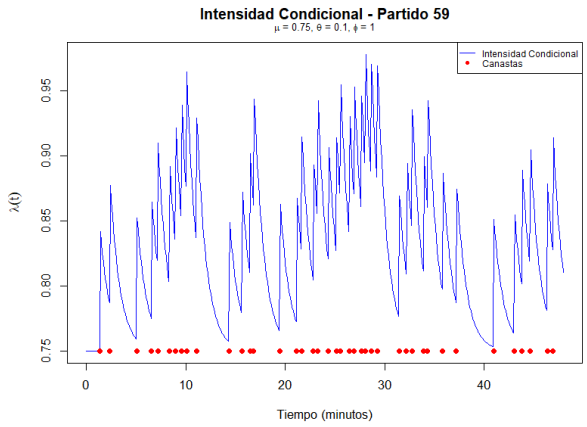


Figura 5.1: Comportamiento intensidad condicional para valores fijos de los parámetros

Una vez analizado la forma que tiene la intensidad condicional asumiendo este modelo, el siguiente paso consiste en estimar los parámetros del modelo. Para ello, es necesario aproximar una parte de la fórmula de la log-verosimilitud: la integral de la intensidad condicional a lo largo del tiempo, que aparece como segundo término tanto en la formulación individual (5.2) como en la conjunta (5.3). Esta integral no puede resolverse de forma exacta.

Con el objetivo de aproximarla de forma eficiente y precisa, consideremos dos reglas clásicas de integración numérica: rectángulo y trapecio.

- **Regla del rectángulo.**

  Tomemos una partición del intervalo de observación $[0, T]$ en n subintervalos equidistantes, tales que:

  $$[0, T] = \bigcup_{i=1}^{n} [t_i, t_{i+1}], \quad \text{con } \Delta t = t_{i+1} - t_i \text{ constante.}$$

  Bajo esta partición, la regla del rectángulo aproxima la función $\lambda(t|\mathcal{H}_t)$ como una constante dentro de cada subintervalo. Es decir, se asume que la intensidad condicional no varía en dicho tramo, y la integral se estima como una suma de áreas de rectángulos:

  $$\int_0^T \lambda(t|\mathcal{H}_t)dt \approx \sum_{i=1}^{n} \lambda(t_i|\mathcal{H}_{t_i}) \cdot \Delta t.$$

  En nuestro caso, elegimos $\Delta t = 1$ (subintervalos de un minuto). Esta elección permite implementar el cálculo de la integral de forma sencilla y eficiente.

- **Regla del trapecio.**

  Al igual que antes, dividimos el intervalo $[0, T]$ en n subintervalos de igual longitud Δt. Sin embargo, esta vez no asumimos que la integral es constante, sino que varía linealmente entre los extremos de cada tramo.

  Esto permite una estimación más precisa de la integral, especialmente cuando la intensidad cambia gradualmente con el tiempo. La fórmula de la aproximación es:

  $$\int_0^T \lambda(t|\mathcal{H}_t)dt \approx \frac{\Delta t}{2} \left(\lambda(t_1|\mathcal{H}_{t_1}) + 2 \sum_{i=2}^{n} \lambda(t_i|\mathcal{H}_{t_i}) + \lambda(t_{n+1}|\mathcal{H}_{t_{n+1}}) \right).$$

  Desde el punto de vista computacional, esta técnica implica un coste ligeramente superior al de la regla del rectángulo. No obstante, su mayor precisión justifica su uso en situaciones donde se necesite mayor exactitud, como en el ajuste conjunto del modelo.

  Por este motivo, en nuestro análisis empleamos la regla del trapecio como método principal de integración, recurriendo al rectángulo en versiones simplificadas del modelo.

5.1.3. Estimación de los parámetros del modelo.

Ahora, ya estamos en condiciones de obtener estimaciones para los parámetros del modelo de intensidad condicional definido en (5.1.3):

$$\lambda(t|\mathcal{H}_t) = \mu + \sum_{t_i<t} \theta \cdot e^{-\phi(t-t_i)},$$

El objetivo es encontrar los valores de μ, θ y ϕ que mejor se ajusten a los datos observados. Para ello, hacemos uso del principio de máxima verosimilitud.

Buscamos maximizar las funciones de log-verosimilitud, tanto en su versión individual como conjunta. Este análisis se llevará a cabo en diferentes niveles: por un lado, considerando al equipo en su conjunto, y por otro, de forma individual para una selección de jugadores destacados por su capacidad anotadora.

Sin embargo, la función de log-verosimilitud no puede resolverse de forma directa ni presenta una expresión sencilla. Esto se debe a que la intensidad depende del tiempo y que incluye una integral que no tiene solución analítica. Por esta razón, es necesario utilizar métodos computacionales de optimización.

En nuestro caso, utilizamos el paquete `DEoptim` de R, que implementa un algoritmo descrito por (Mullen et al., 2011). Este tipo de algoritmo es especialmente útil para problemas donde la función objetivo (log-verosimilitud) puede no ser derivable o contener varios óptimos locales. `DEoptim` trabaja buscando el mínimo global de una función mediante algoritmos evolutivos.

Ahora bien, dado que `DEoptim` está diseñado para minimizar funciones, y nuestro objetivo es maximizar la log-verosimilitud, es necesario aplicar una transformación habitual: minimizar el opuesto de la log-verosimilitud. Es decir, se define una nueva función objetivo como la menos log-verosimilitud, y se busca su valor mínimo. De esta forma, el mínimo encontrado por el algoritmo se corresponde con el máximo de la log-verosimilitud original.

Por último, para aplicar correctamente el algoritmo de optimización, es necesario definir cotas inferiores y superiores para los parámetros del modelo. Estas restricciones se basan en consideraciones prácticas y de sentido común. Todos los parámetros deben ser mayores o iguales que cero, ya que representan tasas o efectos que no pueden ser negativos. Por otro lado, las cotas superiores se fijan en valores razonables que ofrecen suficiente libertad en la estimación.

El procedimiento seguido para implementar la estimación por máxima log-verosimilitud en R se encuentra recogido en el apéndice 7.1. En primer lugar, en el listing 2 se define la función de intensidad condicional del modelo, así como la implementación de la regla del trapecio para aproximar integrales. Además, se establecen cotas inferior y superior para los parámetros a estimar. El listing 3 presenta la función de log-verosimilitud para un único partido, basada en la formulación descrita en (5.2), mientras que en el listing 4 se muestra su versión conjunta, que recorre cada partido del conjunto y acumula los resultados conforme a lo detallado en (5.3). Por último, en listing 5 y listing 6, se aplica el algoritmo `DEoptim` para estimar los parámetros de forma individual y conjunta, respectivamente.

5.1.4. Evaluación del modelo.

Antes de aplicar el modelo a nuestra base de datos, es fundamental comprobar si la implementación en R se ha llevado a cabo correctamente. Para ello, vamos a simular una base de datos artificial sobre la que hemos aplicado nuestros algoritmos de optimización. Si el código ha sido programado de forma adecuada, las estimaciones obtenidas deberían ser cercanas a los valores con los que se simularon los eventos.

Como referencia, fijemos los mismos valores de los parámetros μ_0, θ_0 y ϕ_0 que se utilizaron en la gráfica de la intensidad condicional para el partido 59 (fig. 3.8). Estos valores proporcionan un comportamiento razonable del proceso, por lo que resultan adecuados para calibrar simulaciones con un patrón autoexcitante.

Para generar los datos simulados, empleamos el paquete `stelfi` (Jones-Todd and van Helsdingen, 2024), que permite simular procesos de Hawkes mediante la función *sim_hawkes*. En particular, simulamos un conjunto de partidos en los que se generan eventos que siguen un comportamiento autoexcitante. Una vez construida la base de datos simulada, se aplican los mismos procedimientos de estimación a través de la log-verosimilitud individual (listing 5) y conjunta (listing 6) según se trabaje con uno o varios partidos.

El siguiente fragmento de código muestra el proceso de simulación de un conjunto de k partidos:

```
k <- 10 # Numero de partidos a simular.
mu_0 <- 0.75
theta_0 <- 0.1
phi_0 <- 1
simulacion <- list()
t_max <- 48  # Suponemos 4 cuartos de 12 min.

for (j in 1:k){
  sim_data <- sim_hawkes(mu=mu_0,alpha=theta_0,beta=phi_0,n=48,seed=j)
  sim_data <- sim_data[sim_data<48] #Limitar a 48 minutos cada simulacion
  simulacion[[j]] <-  data.frame(match_id=j,tiempo=sim_data)
}
```

Listing 1: Simulación de un conjunto de k-partidos.

Partidos simulados	$\widehat{\mu}$	$\widehat{\theta}$	$\widehat{\phi}$
1	0.6165733	0.4016070	5.9905660
20	0.7369745	0.2606049	1.5931849
80	0.7615677	0.1651124	1.2633740
100	0.7501026	0.1300174	1.1910619

Cuadro 5.1: Estimaciones recuperadas de datos simulados.

Notemos que, conforme aumenta el número de partidos simulados, las estimaciones se aproximan de

forma progresiva a los valores prefijados $(\mu_0, \theta_0, \phi_0) = (0.75, 0.1, 1)$. Esto respalda la validez de la implementación y su capacidad para recuperar los parámetros del modelo.

5.2. Resultados Principales.

En esta sección se recogen los principales resultados obtenidos al aplicar el modelo propuesto sobre las canastas de dos y tres puntos anotadas por los Chicago Bulls en la temporada 2022-2023. El análisis se centrará en evaluar la presencia de comportamientos autoexcitantes en la secuencia de anotaciones, estimando los parámetros del modelo y representando gráficamente los casos más destacados. Además, con el fin de valorar el ajuste del modelo implementado, se compararán los resultados obtenidos con los proporcionados por el paquete `stelfi`.

5.2.1. Estimación partido a partido.

Como primer paso del análisis se llevó a cabo la estimación de los parámetros del modelo a nivel de equipo, considerando cada uno de los partidos disputados por los Chicago Bulls por separado. Esta estimación se realizó mediante el método de optimización de la log-verosimilitud individual que se implementó en (listing 5). Además, se compararon estas estimaciones con las que genera el paquete `stelfi` a partir de la función *fit_hawkes*.

Match ID	**Método**	$\widehat{\boldsymbol{\mu}}$	$\widehat{\boldsymbol{\theta}}$	$\widehat{\boldsymbol{\phi}}$	− Log-verosimilitud
7	DEoptim	0.5898	0.0293	0.1189	45.5866
	stelfi	0.6155	0.0184	0.0305	46.7736
38	DEoptim	0.8538	0.0167	0.3480	46.8247
	stelfi	0.9616	0.0000	0.0003	47.8406
46	DEoptim	0.7730	0.0145	0.0629	46.8329
	stelfi	0.7566	0.0117	0.0128	47.8798
54	DEoptim	0.5823	0.0183	0.1255	44.2661
	stelfi	0.5913	0.0130	0.0570	44.9768
70	DEoptim	0.8869	0.0213	0.3625	46.9568
	stelfi	0.9726	0.0000	3.7220	47.9350

Cuadro 5.2: Comparación de estimaciones entre `DEoptim` y `stelfi` para partidos seleccionados.

Para garantizar una comparación justa entre ambos enfoques, tanto el código desarrollado con el paquete `DEoptim` como las funciones de `stelfi` se ejecutaron con un total de 1000 iteraciones. Bajo estas condiciones equivalentes, el procedimiento basado en `DEoptim` proporcionó valores más bajos de la $-$log-verosimilitud en comparación con los obtenidos mediante `stelfi`. Dado que esta función fue definida con signo negativo para permitir su minimización, un valor más bajo indica un mejor ajuste del modelo a los datos. Por tanto, en los partidos analizados, el método basado en la optimización directa ofrece un ajuste superior.

Antes de mostrar las representaciones gráficas, conviene señalar que no se incluirán todos los partidos analizados, sino una selección de aquellos más representativos en términos de comportamiento auto-

excitante. Para ello, se ha optado por escoger el partido con mayor valor estimado del parámetro θ, que refleja mejor la dependencia temporal entre canastas según el modelo. En las fig. 5.2 y fig. 5.3 se muestran la intensidad estimada por ambos métodos junto a las canastas anotadas.

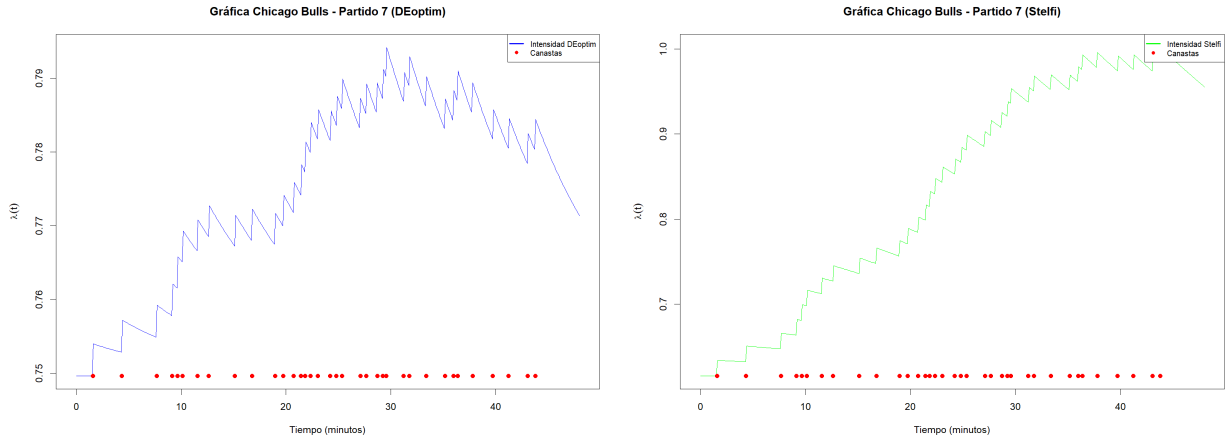


Figura 5.2: Comparación de la Intensidad Condicional `DEoptim` y `stelfi` - Chicago Bulls, Partido 7.

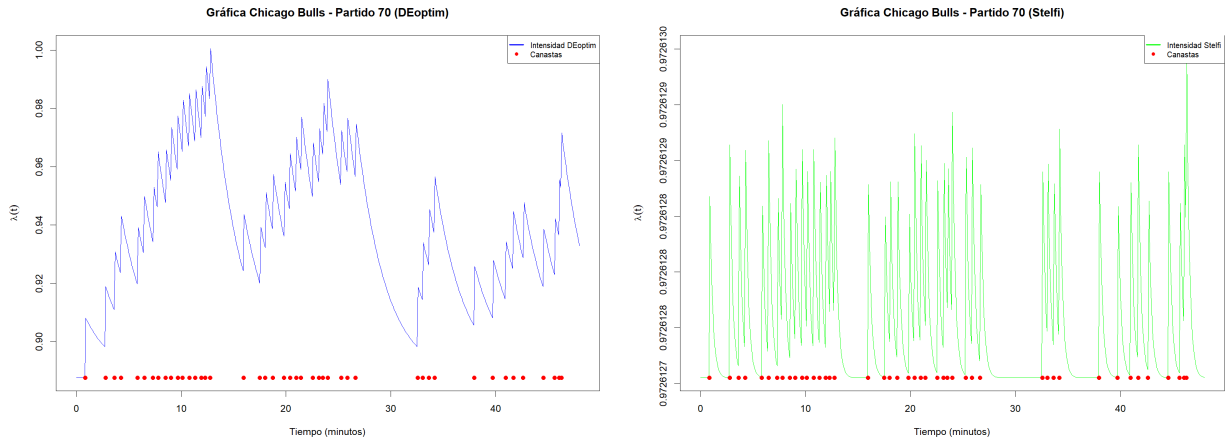


Figura 5.3: Comparación de la Intensidad Condicional `DEoptim` y `stelfi` - Chicago Bulls, Partido 70.

Sin embargo, este análisis puede aplicarse también a aquellos jugadores con mayor promedio de anotaciones por partido. Las estimaciones completas de los parámetros correspondientes a los partidos más representativos de cada jugador se incluyen en el apéndice 7.2.Con el fin de evitar redundancias, se presenta una única gráfica por jugador, asociada al partido en el que se obtuvo el mayor valor de θ estimado.

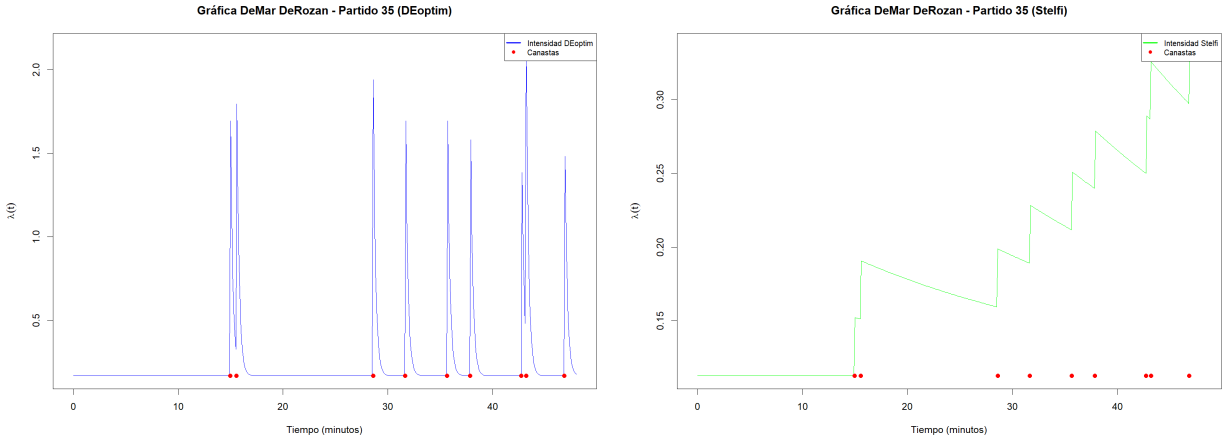


Figura 5.4: Comparación de la Intensidad Condicional `DEoptim` y `stelfi` - DeMar DeRozan, Partido 35.

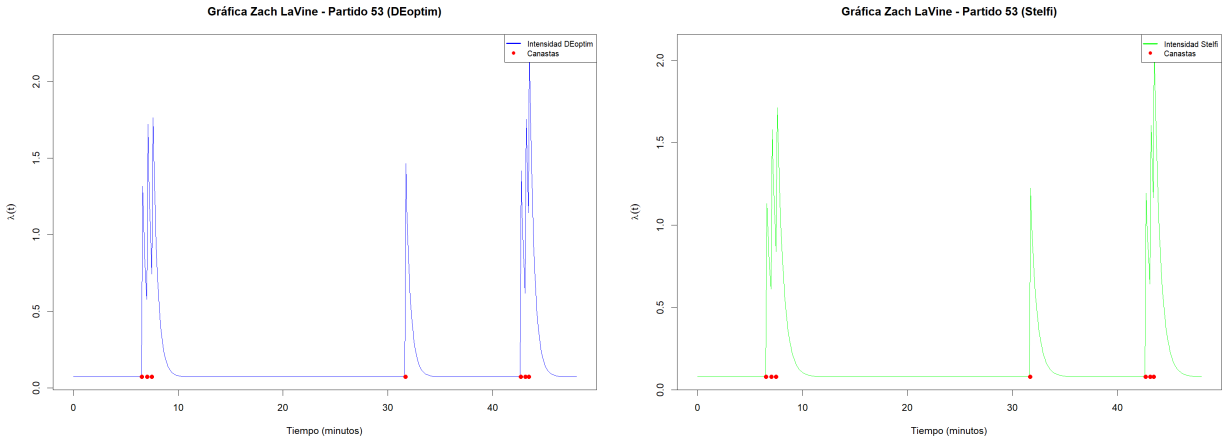


Figura 5.5: Comparación de la Intensidad Condicional `DEoptim` y `stelfi` - Zach LaVine, Partido 53.

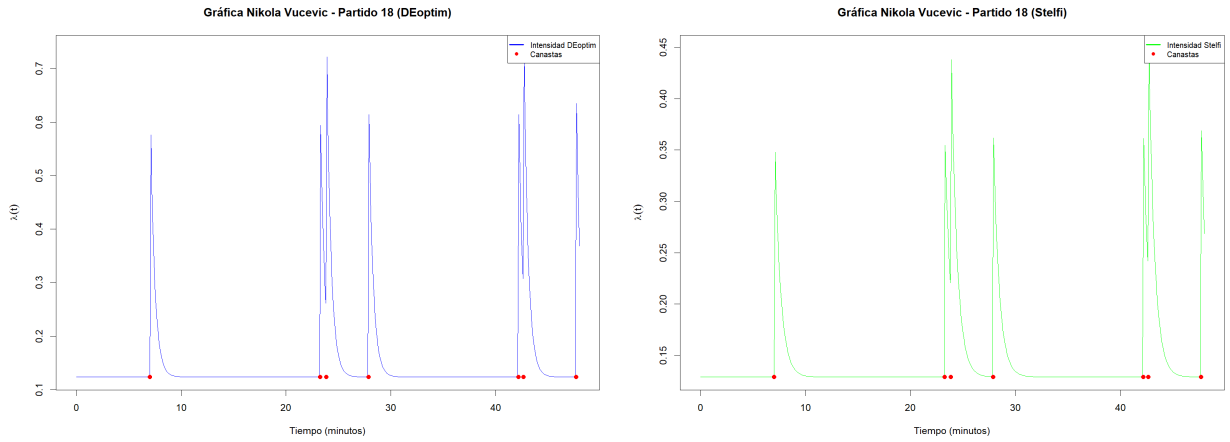


Figura 5.6: Comparación de la Intensidad Condicional `DEoptim` y `stelfi` - Nikola Vucevic, Partido 18.

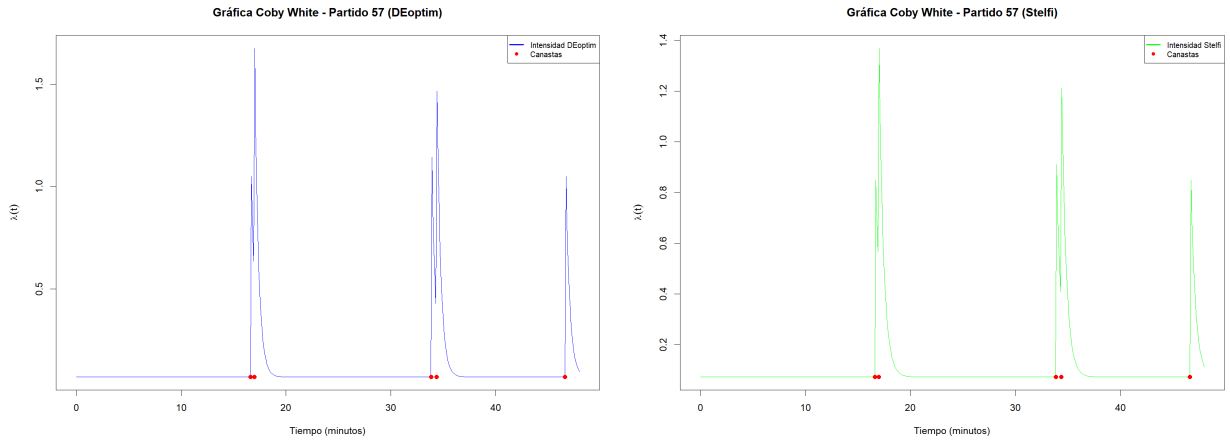


Figura 5.7: Comparación de la Intensidad Condicional `DEoptim` y `stelfi` - Coby White, Partido 57.

Las representaciones gráficas permiten visualizar el comportamiento autoexcitante de las anotaciones, tanto a nivel de equipo como jugador. En el caso de los Chicago Bulls, se aprecia cómo tras una canasta la intensidad del proceso aumenta, lo que indica que es más probable que ocurra otra anotación poco después. Este comportamiento encaja con la idea de rachas de anotación, algo habitual en la dinámica de un partido de baloncesto.

Cuando el análisis se traslada a nivel individual, los efectos autoexcitantes se hacen aún más visibles. Esto ocurre ya que un jugador anota menos veces por partido que el equipo en conjunto, por lo que una sola racha tiene un mayor impacto en la intensidad. De hecho, el modelo detecta momentos muy marcados en los que el jugador encadena varias canastas en poco tiempo. Esto se asocia con el fenómeno conocido como *hot hand*, donde el jugador entra en una dinámica anotadora.

Por tanto, ahora somos capaces no solo de entender el rendimiento individual, sino el estilo de anotación de cada jugador. Por ejemplo, DeRozan destaca por tener un aporte más constante a lo largo del partido (menos partidos autoexcitados) mientras que Zach LaVine se caracteriza por su impacto más explosivo en momentos concretos del encuentro.

5.2.2. Estimación conjunta sobre los partidos destacados.

Además de los resultados individuales, nuestro código presenta una ventaja importante frente al paquete `stelfi`. No solo proporciona estimaciones más precisas en términos de la log-verosimilitud, lo que indica un mejor ajuste a los datos, sino que también permite realizar el análisis de forma conjunta a varios partidos. En este apartado, vamos a aplicar el procedimiento desarrollado en listing 6 al conjunto de encuentros destacados en la subsección anterior. Esto nos permitirá obtener estimaciones más estables, tanto para el equipo como para los jugadores más anotadores.

Caso	**nº Partidos**	$\widehat{\boldsymbol{\mu}}$	$\widehat{\boldsymbol{\theta}}$	$\widehat{\boldsymbol{\phi}}$	**−Log-verosimilitud**
Chicago Bulls	5	0.826055450	0.006562324	0.184210560	232.2332
DeMar DeRozan	11	0.17652246	0.03440759	0.76224935	265.8681
Zach LaVine	17	0.1333982	0.2829292	0.9373598	382.2403
Nikola Vucevic	17	0.1479304	0.1155804	1.0294395	317.9342
Coby White	20	0.07691724	0.22808853	0.72977729	278.3863

Cuadro 5.3: Estimaciones de los parámetros sobre el conjunto de partidos destacados.

Ahora bien, notemos que las estimaciones obtenidas al considerar los partidos como un único conjunto de datos ordenado nos aportan una visión global del patrón de anotación, tanto a nivel de equipo como individual. Por ello, procedemos a graficar la intensidad condicional en estos encuentros utilizando los parámetros estimados provenientes de la log-verosimilitud conjunta.

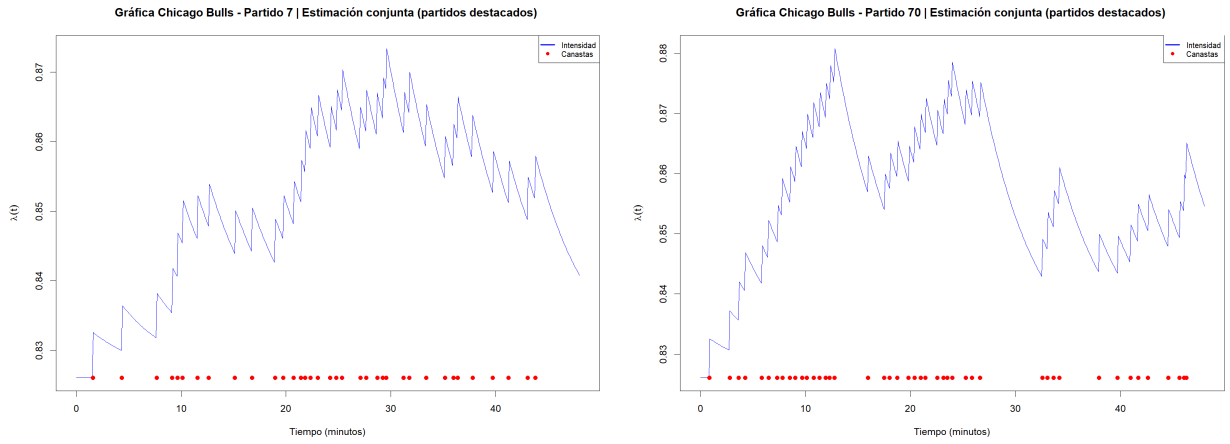


Figura 5.8: Intensidad Condicional de los Chicago Bulls para los Partidos Destacados Analizados Conjuntamente.

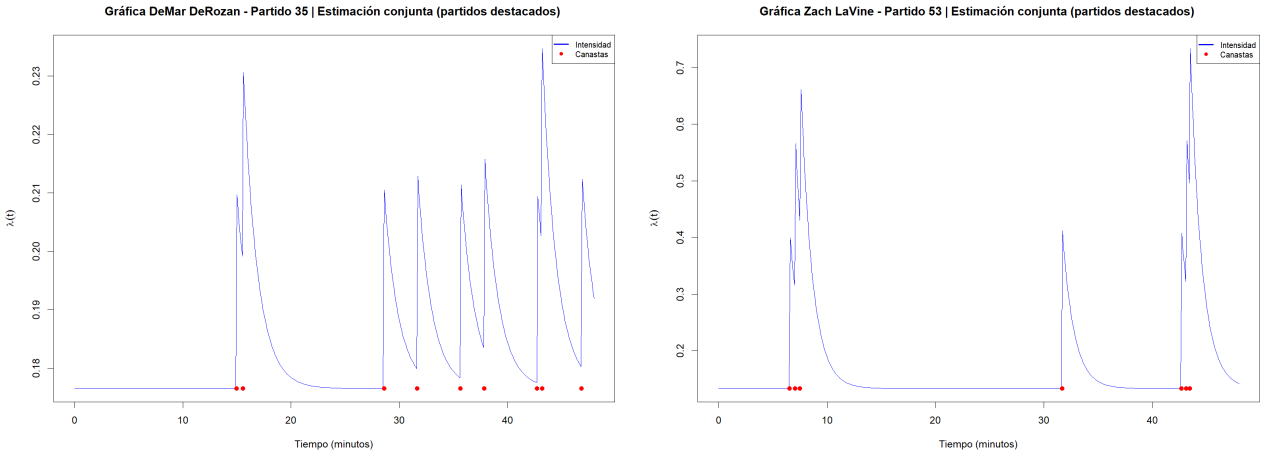


Figura 5.9: Intensidad Condicional de DeMar DeRozan y Zach LaVine para los Partidos Destacados Analizados Conjuntamente.

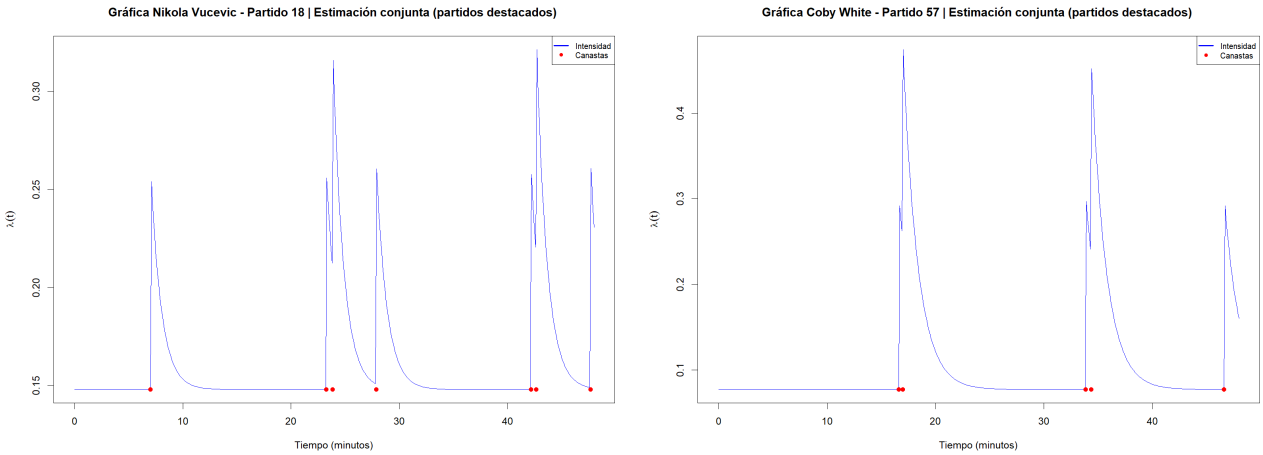


Figura 5.10: Intensidad Condicional de Nikola Vucevic y Coby White para los Partidos Destacados Analizados Conjuntamente.

Las gráficas resultantes muestran que las estimaciones conjuntas generan curvas de intensidad que encajan bien con las rachas de anotación observadas en los partidos. A pesar de ser un único conjunto de parámetros, el modelo sigue captando el comportamiento característico de un proceso autoexcitante.

5.2.3. Estimación conjunta sobre todos los partidos de la temporada.

Nos planteamos ahora qué ocurriría si analizamos el conjunto completo de partidos disputados durante la temporada. El objetivo es comprobar si, al tratar todos estos encuentros como un único bloque de datos ordenados, el modelo sigue detectando un patrón de comportamiento autoexcitante como ocurría

en el apartado anterior. La siguiente tabla recoge las estimaciones obtenidas para los parámetros del modelo:

Caso	**nº Partidos**	$\widehat{\boldsymbol{\mu}}$	$\widehat{\boldsymbol{\theta}}$	$\widehat{\boldsymbol{\phi}}$	**−Log-verosimilitud**
Chicago Bulls	84	8.930629e-01	4.434563e-16	6.606074e+01	3969.309
DeMar DeRozan	75	1.966259e-01	2.555194e-15	7.207349e+01	1775.482
Zach LaVine	79	1.951426e-01	1.369235e-16	3.538294e+01	1820.111
Nikola Vucevic	84	1.734055e-01	2.142164e-16	5.798918e+01	1676.043
Coby White	70	8.065810e-02	9.525838e-03	6.464186e-12	903.9015

Cuadro 5.4: Estimaciones conjuntas de los parámetros del modelo para equipo y jugadores.

Sin embargo, al observar los resultados de la tabla, destaca especialmente el valor estimado de $\widehat{\theta}$, que es el encargado de capturar la dependencia temporal entre eventos, es decir, el componente de autoexcitación del modelo. En todos los casos, tanto a nivel equipo como individual, este parámetro toma valores muy cercanos a cero. Esto indica que, al considerar todos los partidos de la temporada como un único conjunto de datos ordenado, el modelo no logra capturar un efecto de autoexcitación.

A lo largo de la temporada, hay partidos en los que sí se observa un comportamiento autoexcitante claro. Sin embargo, también hay otros momentos en los que el ritmo de anotación es más regular o incluso aleatorio. Al unir todos estos partidos en un solo análisis, estos efectos opuestos se neutralizan, es decir, las rachas de anotación detectadas en unos partidos quedan opacadas por los patrones más planos de otros. Como resultado, el modelo no percibe una tendencia general hacia la autoexcitación, y por ello la estimación de θ es prácticamente nula en el análisis conjunto.

5.3. Intervalos de Confianza para los Parámetros del Modelo.

Hasta ahora, el análisis se ha centrado en la estimación puntual de los parámetros del modelo, tanto a nivel de equipo como de jugador. Sin embargo, para obtener una evaluación más completa y rigurosa del ajuste, es importante acompañar estas estimaciones de sus respectivos intervalos de confianza.

En esta sección, nos proponemos construir intervalos de confianza para los parámetros μ, θ y ϕ del modelo, considerando exclusivamente los partidos de los Chicago Bulls. Este procedimiento se realizará en dos fases: una centrada en los partidos destacados de forma individual, y otra que considera todos los partidos seleccionados en conjunto.

5.3.1. Intervalos por partido.

En primer lugar, nos centraremos en aquellos partidos en los que se observaron rasgos de autoexcitación por parte de los Chicago Bulls. El objetivo es evaluar la consistencia de las estimaciones obtenidas para los parámetros del modelo. Para ello, planteamos un procedimiento que nos permita construir intervalos de confianza a partir de simulaciones generadas por el propio modelo. De este modo, podremos evaluar la estabilidad de las estimaciones bajo condiciones controladas. Para un único partido el proceso se estructura en los siguientes pasos:

1. **Simulación de eventos.** se generan J simulaciones de un partido, cada una con n canastas, en los tiempos $\{t_{j,k}\}_{k=1}^{n}$, donde $j \in \{1, \ldots, J\}$ representa el partido. La generación de estos tiempos se realiza utilizando la función *sim_hawkes*.

2. **Estimación de parámetros**: sobre cada partido simulado, se aplica nuevamente el código basado en `DEoptim`, obteniendo así B estimaciones para cada parámetro del modelo:

$$\widehat{\mu_j},\, \widehat{\theta}_j,\, \widehat{\phi_j} \quad \text{para } j \in \{1, \cdots, J\}.$$

3. **Construcción intervalos de confianza:** utilizando los percentiles 2.5 % y 97.5 % obtenemos:

$$IC_{95\,\%}(\mu) = \text{quantile}(\{\widehat{\mu_j}\}_{j=1}^{J}, (0.025, 0.975)).$$

$$IC_{95\,\%}(\theta) = \text{quantile}(\{\widehat{\theta}_j\}_{j=1}^{J}, (0.025, 0.975)).$$

$$IC_{95\,\%}(\phi) = \text{quantile}(\{\widehat{\phi_j}\}_{j=1}^{J}, (0.025, 0.975)).$$

Para asegurar la reproducibilidad de los resultados, se fijan semillas aleatorias en todas las simulaciones y optimizaciones. Esto permite que sean replicables en futuras ejecuciones y que al aumentar el número de simulaciones el método vaya previsiblemente mejor.

Match ID	$\boldsymbol{IC_{95\,\%}(\mu)}$	$\boldsymbol{IC_{95\,\%}(\theta)}$	$\boldsymbol{IC_{95\,\%}(\phi)}$
7	[0.4579 , 0.9873]	[2.339e-16 , 2]	[8.876e-04 , 99.988]
38	[0.2564 , 0.9736]	[8.087e-16 , 2]	[1.564e-03 , 89.964]
46	[0.2721 , 1.0210]	[3.428e-16 , 2]	[1.682e-09 , 100]
54	[0.3278 , 0.9012]	[1.101e-16 , 2]	[7.905e-04 , 100]
70	[0.0896 , 0.8856]	[0.0022 , 2]	[9.188e-18 , 53.4429]

Cuadro 5.5: Intervalos de Confianza para estimaciones de los parámetros sobre partidos seleccionados.

Estos intervalos se han construido a partir de 50 simulaciones para cada partido, generadas con los parámetros estimados en la (table 5.5). Notemos que, en todos estos partidos, las estimaciones puntuales se encuentran contenidas dentro de sus respectivos intervalos.

Sin embargo, los intervalos son notablemente amplios, especialmente en los parámetros θ y ϕ. En particular, se llegan a alcanzar las cotas fijadas en la optimización o se sitúan muy cerca de cero. Esta amplitud puede explicarse, en parte, por el número limitado de eventos por partido o de simulaciones, que reducen la capacidad de captar los parámetros con precisión. Además, alguno de ellos, como ϕ, puede ser más difícil de recuperar con claridad a partir de los datos observados, ya que distintos valores de dicho parámetro generan efectos similares sobre la función de intensidad.

De hecho, las simulaciones suponen un aporte adicional de variabilidad, ya que cada ajuste se realiza sobre datos simulados aleatoriamente. No obstante, que las estimaciones se mantengan dentro de los intervalos construidos respalda la coherencia y consistencia del proceso seguido.

5.3.2. Intervalos en conjunto de partidos.

Al igual que en el caso individual, también es posible construir intervalos de confianza a partir de estimaciones generadas sobre conjuntos de partidos simulados. Para ello, planteamos el siguiente procedimiento:

1. **Simulación de eventos:** para un conjunto de S partidos, se generan J simulaciones independientes. En cada una de ellas, se simulan S partidos con n eventos cada uno. Denotamos los tiempos simulados $\{t^s_{j,k}\}_{k=1}^n$, donde,

   - $s \in \{1, \ldots, S\}$ representa el partido.
   - $j \in \{1, \ldots, J\}$ hace referencia a la simulación correspondiente.

   La generación de estos tiempos se realiza utilizando la función *sim_hawkes*:

2. **Estimación de parámetros**: sobre cada conjunto de S partidos simulados, se aplica el código basado `DEoptim`, obteniendo así J estimaciones para cada parámetro del modelo:

$$\widehat{\mu_j},\, \widehat{\theta}_j,\, \widehat{\phi}_j \quad \text{para } j \in \{1, \cdots, J\}.$$

3. **Construcción intervalos de confianza:** utilizando los percentiles 2.5 % y 97.5 % obtenemos:

$$IC_{95\,\%}(\mu) = \text{quantile}(\{\widehat{\mu_j}\}_{j=1}^J, (0.025, 0.975)).$$
$$IC_{95\,\%}(\theta) = \text{quantile}(\{\widehat{\theta}_j\}_{j=1}^J, (0.025, 0.975)).$$
$$IC_{95\,\%}(\phi) = \text{quantile}(\{\widehat{\phi}_j\}_{j=1}^J, (0.025, 0.975)).$$

Caso	$\boldsymbol{IC_{95\,\%}(\mu)}$	$\boldsymbol{IC_{95\,\%}(\theta)}$	$\boldsymbol{IC_{95\,\%}(\phi)}$
Chicago Bulls	[0.7736 , 0.9221]	[0.0048 , 0.2980]	[0.10745 , 100]

Cuadro 5.6: Intervalos de Confianza para estimaciones de los parámetros sobre conjunto de partidos seleccionados.

En la (table 5.6) se han realizado un total de $J = 20$ simulaciones, cada una compuesta por $S = 50$ partidos generados a partir de los parámetros estimados anteriormente. En efecto, las estimaciones puntuales (table 5.3) se encuentran dentro de los intervalos obtenidos, que, además, destacan por ser más acotados que en el caso individual. Este resultado era de esperar, ya que trabajar con un mayor volumen de datos permite mejorar en la precisión de las estimaciones y reducir su variabilidad.

Ahora, el intervalo asociado a θ es mucho más estrecho, lo que indica que el comportamiento autoexcitante del proceso puede estimarse con mayor confianza en esta situación. Sin embargo, el intervalo asociado a ϕ sigue siendo relativamente amplio. Esto puede deberse a la dificultad para identificar este parámetro con claridad, ya que distintos valores de ϕ producen efectos muy similares sobre la intensidad del proceso, lo que dificulta su detección.

Capítulo 6

Conclusiones

El objetivo de este trabajo ha sido buscar evidencia estadística sobre la existencia del efecto *hot hand* en baloncesto, es decir, estudiar si encestar una canasta aumenta la probabilidad de anotar otra poco después. A pesar de que se trata de una idea muy presente en el ambiente deportivo, su validez ha sido cuestionada desde hace décadas. Para contribuir a este debate, y en busca de patrones temporales que puedan reflejar rachas de anotación, se han utilizado modelos autoexcitantes aplicados a las canastas de dos y tres puntos de los Chicago Bulls durante la temporada 2022-2023.

Los resultados muestran que, aunque no todos los partidos presentan un comportamiento autoexcitante claro, sí se identifican casos en los que el modelo detecta rachas de anotación tanto a nivel de equipo como individual. Sin embargo, es en el análisis individual donde este enfoque resulta especialmente revelador. No solo se identifican más partidos con rasgos autoexcitantes, sino que además permite caracterizar el estilo de anotación de cada jugador. En ese sentido, DeMar DeRozan y Zach LaVine, los dos máximos anotadores del equipo durante la temporada, ofrecen un ejemplo muy ilustrativo. A pesar de que ambos acumulen un volumen similar de puntos, lo hacen de forma distinta. DeRozan destaca por su anotación constante y uniforme a lo largo del partido, mostrando un perfil más regular. En cambio, LaVine tiende a concentrar sus aciertos en momentos puntuales, mostrando una dinámica más intermitente y explosiva. Esta distinción no solo valida la utilidad del modelo, sino que también abre la puerta a nuevas formas de estudiar el rendimiento e impacto de los jugadores según sus patrones de anotación.

Además del análisis realizado, cabe destacar que la implementación desarrollada permite aplicar el modelo a varios partidos de manera simultánea. Esto facilita extender el estudio más allá de series temporales individuales, abriendo la puerta a estudios longitudinales en los que se compare el comportamiento anotador a lo largo de una temporada. A diferencia de herramientas como `stelfi`, centradas en el análisis partido a partido, este planteamiento ofrece mayor flexibilidad para evaluar patrones generales y contrastar resultados entre encuentros.

Una vez construido y validado el modelo autoexcitante, resulta natural preguntarse si existen formas de ampliarlo o adaptarlo para captar mejor algunos matices en la dinámica del juego. Una de las líneas más prometedoras consiste en estudiar el efecto del *home court*, es decir, si jugar como local influye

en el comportamiento anotador. Para ello, se podría plantear una modificación en el modelo original que diferencie ciertos parámetros según la condición de local o visitante. La intensidad condicional resultante tendría la siguiente forma:

$$\lambda(t|\mathcal{H}_t) = \begin{cases} \mu_{\text{home}} + \sum_{t_i<t} \theta_{\text{home}} \cdot e^{-\phi(t-t_i)}, & \text{si el partido se juega en casa,} \\ \mu_{\text{away}} + \sum_{t_i<t} \theta_{\text{away}} \cdot e^{-\phi(t-t_i)}, & \text{si el partido se juega fuera.} \end{cases}$$

En esta formulación, μ_{home} y μ_{away} representan la tasa de fondo en partidos disputados como local y visitante, respectivamente. Por su parte, θ_{home} y θ_{away} permiten distinguir el grado de autoexcitación según el lugar en el que se juegue el partido. Esta distinción nos permitiría analizar si las rachas se ven favorecidas por el ambiente local, en vistas de poder cuantificar el *home court effect.*

Otra extensión útil sería incorporar el tiempo efectivo en pista de cada jugador, ya que este factor podría influir en su capacidad anotadora. Para ello, se podría plantear un modelo en el que la tasa de fondo dependa del tiempo acumulado en juego. Por ejemplo:

$$\lambda(t|\mathcal{H}_t) = \mu_0 + \mu_1 \cdot M(t) + \sum_{t_i<t} \theta \cdot e^{-\phi(t-t_i)},$$

donde $M(t)$ es la cantidad de minutos que ha estado el jugador en pista hasta el instante t. En este contexto, μ_1 permite analizar cómo afecta ese tiempo acumulado a la intensidad de anotación. Un valor negativo de μ_1 podría reflejar un efecto de fatiga que reduce la propensión a anotar a medida que pasan los minutos. Por el contrario, un valor positivo sugeriría que el jugador entra progresivamente más en ritmo ofensivo conforme avanza el partido.

También se podría considerar un modelo con marcas que tengan en cuenta el tipo de canasta anotada, es decir, que distinga entre tiros de dos y tres puntos. Esto permitiría analizar qué tipos de anotación provocan más rachas, ofreciendo así una visión más detallada sobre las acciones que más influyen en la dinámica ofensiva del juego.

Por otro lado, se puede considerar el enfoque bayesiano. Este tipo de modelo resulta especialmente ventajoso cuando se dispone de pocas observaciones o cuando se desea incorporar efectos aleatorios con mayor facilidad. Un ejemplo de este enfoque aplicado a procesos puntuales puede encontrarse en Briz-Redón and Mateu (2024).

Por último, merece una mención especial el trabajo de Bocskocsky et al. (2014), que representa uno de los estudios más completos sobre el efecto *hot hand*. A través del uso de datos de seguimiento del balón y de los jugadores, los autores incorporan variables contextuales como la posición del tiro o la precisión defensiva para aportar evidencia a favor de la existencia de rachas de anotación en condiciones reales de juego. Este enfoque demuestra cómo bases de datos más detalladas pueden aportar nuevas perspectivas en el debate sobre la existencia matemática del *hot hand*.

Capítulo 7

Apéndice

7.1. Códigos para la estimación por máxima verosimilitud.

```r
# Intensidad Condicional:
intensidad <- function(t,t_previos,mu,theta,phi){
  mu+sum(theta*exp(-phi*(t-t_previos[t_previos<t])))
}

#  Regla del trapecio
trapecio_integral <- function(a, b, n, f)
  {
  t <- seq(a, b, length.out = n + 1)
  h <- (b - a) / n
  integral_aprox <- (h / 2) * (f(a) + 2 * sum(sapply(t[2:n], f)) + f(b))
  return(integral_aprox)
  }

# Cotas
lower_bounds <- c(0, 0, 0)
upper_bounds <- c(2, 2, 100)
```

Listing 2: Definición Intensidad Condicional y Regla del Trapecio

```r
log_verosimilitud_individual <- function(x, chi, t_max)
  {
    mu <- x[1]
    theta <- x[2]
    phi <- x[3]
    lambda_integral <- 0
    t_previos <- chi$tiempo
    tiempos <- seq(0.5, t_max-0.5, by = 1)

    # Primer termino: Suma de log(lambda(t_i))
    lambda <- sapply(t_previos,function(t){intensidad(t,t_previos,mu,theta,
        phi)})
    sum_lambda_log <- sum(log(pmax(lambda, .Machine$double.eps)))

    # Segundo termino: Integral de lambda(t) en [0,t_max] con trapecio.
    lambda_integral <- lambda_integral + trapecio_integral(0.5,t_max-0.5,
        length(tiempos), function(t){intensidad(t,t_previos,mu,theta,phi)})
    logL <- sum_lambda_log-lambda_integral
    return(-logL)
  }
```

Listing 3: Definición log-verosimilitud individual

```r
log_verosimilitud_conjunta <- function(x, k, chi, t_max)
  {
    mu <- x[1]
    theta <- x[2]
    phi <- x[3]
    sum_lambda_log <- 0
    sum_lambda_integral <- 0

   for (j in 1:k)
    {
      # Equipo
      t_previos <- chi[chi$match_id == j, ]$tiempo
      # Jugador
      #t_previos <- chi[chi$contador == j, ]$tiempo

      tiempos <- seq(0.5, t_max[j]-0.5, by = 1)

      # Primer termino: Suma de log(lambda(t_i)) desde el primer partido
         hasta el k-esimo partido
      lambda <- sapply(t_previos,function(t){intensidad(t,t_previos,mu,theta
         ,phi)})
      sum_lambda_log <- sum_lambda_log+sum(log(pmax(lambda, .Machine$double.
         eps)))

      # Segundo termino: Integral de lambda(t) en [0,t_max] con trapecio.
       sum_lambda_integral <- sum_lambda_integral - trapecio_integral(0.5, t
          _max[j] - 0.5, length(tiempos),
          function(t) {intensidad(t, t_previos, mu, theta, phi)})
    }
    logL <- sum_lambda_log+sum_lambda_integral
    return(-logL)
  }
```

Listing 4: Definición log-verosimilitud conjunta

```r
j <- 59 # partido en especifico a analizar.

result_individual <- DEoptim(
    fn = log_verosimilitud_individual,
    lower = lower_bounds,
    upper = upper_bounds,
    control = DEoptim.control(itermax = 1000, trace = FALSE),
    # Equipo
    chi = CHI[CHI$match_id==j,],
    # Jugador
    #chi = JUGADOR[JUGADOR$contador==j,],
    t_max = t_max[j]
      )

result_individual <- list(match_id = j,optim_params = result_individual$
   optim$bestmem, Verosimilitud = result_individual$optim$bestval, last_iter
   =result_individual$member$pop)
result_individual
```

Listing 5: Uso del DEoptim para datos partido a partido.

```r
k <- 84                                 # Equipo.
#k <- max(unique(JUGADOR$contador)) # Jugador.

result_conjunto<- DEoptim(
    fn = log_verosimilitud_conjunta,
    lower = lower_bounds,
    upper = upper_bounds,
    control = DEoptim.control( itermax = 1000, trace = FALSE),
    k = k,
    # Equipo
    chi = CHI[CHI$match_id %in% 1:k,],
    # Jugador
    #chi = JUGADOR[JUGADOR$contador %in% 1:k,],
    t_max = t_max
      )

result_conjunto <- list(numer_of_games=k, optim_params=result_conjunto$optim
   $bestmem, Verosimilitud=result_conjunto$optim$bestval, last_iter=result_
   conjunto$member$pop)

result_conjunto
```

Listing 6: Uso del DEoptim para conjunto de partidos.

7.2. Comparación de parámetros estimados por jugador en partidos representativos.

Match ID	**Método**	$\widehat{\boldsymbol{\mu}}$	$\widehat{\boldsymbol{\theta}}$	$\widehat{\boldsymbol{\phi}}$	− Log-verosimilitud
10	DEoptim	0.2629	0.1049	2.4043	29.9641
	stelfi	0.3043	0.0000	0.2033	30.0733
35	DEoptim	0.1667	**1.9145**	4.5207	23.7254
	stelfi	0.1126	0.0396	0.0396	24.8547
38	DEoptim	0.1455	0.0962	0.7508	22.1886
	stelfi	0.1337	0.1566	0.4192	23.3269
46	DEoptim	0.1941	0.1639	0.8989	27.0417
	stelfi	0.1572	0.0314	0.0314	27.0399
50	DEoptim	0.1540	0.0375	0.4777	22.3076
	stelfi	0.1502	0.0846	0.4008	22.3937
53	DEoptim	0.1372	0.0923	0.5624	22.1808
	stelfi	0.1610	0.1431	0.4788	22.4856
60	DEoptim	0.2122	0.0456	0.9953	20.0229
	stelfi	0.3171	0.0000	25.8306	20.6037
70	DEoptim	0.2012	0.0895	1.9481	25.6695
	stelfi	0.2192	0.0000	39.9406	25.6994
74	DEoptim	0.1281	0.1669	1.5899	20.2730
	stelfi	0.1566	0.3046	1.5034	20.5855
75	DEoptim	0.1435	0.1649	1.1889	22.1739
	stelfi	0.1793	0.1610	1.1636	22.3405
76	DEoptim	0.1532	0.0548	0.2672	23.9422
	stelfi	0.1308	0.1233	0.2893	24.0408

Cuadro 7.1: Comparación de estimaciones entre `DEoptim` y `stelfi` para DeMar DeRozan.

Match ID	**Método**	$\widehat{\boldsymbol{\mu}}$	$\widehat{\boldsymbol{\theta}}$	$\widehat{\boldsymbol{\phi}}$	− Log-verosimilitud
3	DEoptim	0.1640	0.0708	0.5870	23.9341
	stelfi	0.1891	0.0958	0.6683	24.0412
5	DEoptim	0.0954	0.2147	0.9050	18.0828
	stelfi	0.1216	0.2410	0.9054	18.2327
13	DEoptim	0.1537	0.2451	1.3231	23.6461
	stelfi	0.1747	0.2523	1.2994	23.7087
24	DEoptim	0.1316	0.2687	1.1780	21.7850
	stelfi	0.1391	0.2428	0.7556	21.9713
25	DEoptim	0.1449	0.1423	0.5525	18.1647
	stelfi	0.1753	0.1571	0.5564	18.2687
26	DEoptim	0.1658	0.0253	1.0875	24.9532
	stelfi	0.1582	0.1244	1.0804	25.0234
30	DEoptim	0.0836	0.4702	1.2026	18.5623
	stelfi	0.0916	0.7025	1.2359	18.7935
32	DEoptim	0.1795	0.2910	0.8639	27.9488
	stelfi	0.1844	0.2391	0.7867	27.9623
33	DEoptim	0.1284	0.6260	1.5404	22.6698
	stelfi	0.0768	0.1093	0.1093	23.2961
36	DEoptim	0.0762	0.5805	1.5883	16.8507
	stelfi	0.0818	0.8150	1.4214	17.1083
40	DEoptim	0.1781	0.4764	1.3164	27.7528
	stelfi	0.1934	0.2222	0.7755	27.9033
46	DEoptim	0.1360	0.0594	0.8163	20.4277
	stelfi	0.1407	0.0665	0.6799	20.4411
47	DEoptim	0.1031	0.1080	1.4979	12.7479
	stelfi	0.1372	0.1974	1.2933	13.0007
53	DEoptim	0.0713	**1.4475**	2.2501	16.3561
	stelfi	0.0790	1.1782	1.7026	16.5345
55	DEoptim	0.3015	0.0536	0.5429	33.5254
	stelfi	0.2805	0.1187	0.6381	33.5866
78	DEoptim	0.2037	0.3027	1.1058	29.2788
	stelfi	0.1889	0.1877	0.4293	29.5195
82	DEoptim	0.1284	0.3136	1.4178	16.4073
	stelfi	0.1816	0.4360	1.3688	16.8234

Cuadro 7.2: Comparación de estimaciones entre `DEoptim` y `stelfi` para Zach LaVine.

Match ID	**Método**	$\widehat{\boldsymbol{\mu}}$	$\widehat{\boldsymbol{\theta}}$	$\widehat{\boldsymbol{\phi}}$	− Log-verosimilitud
5	DEoptim	0.0587	0.2439	0.5064	15.2006
	stelfi	0.0579	0.3309	0.5788	15.2454
9	DEoptim	0.1288	0.2464	3.6755	14.7979
	stelfi	0.1628	0.2903	2.6764	14.9916
18	DEoptim	0.1234	**0.5547**	2.4539	20.0932
	stelfi	0.1290	0.2543	1.7994	20.1541
19	DEoptim	0.1667	0.0168	1.6183	16.7492
	stelfi	0.2260	0.0000	11.5433	17.0591
21	DEoptim	0.0863	0.1817	1.0450	16.1282
	stelfi	0.0973	0.2439	1.0168	16.1998
27	DEoptim	0.2333	0.1002	1.3232	21.4406
	stelfi	0.2592	0.0781	0.9732	21.5055
33	DEoptim	0.1003	0.1443	1.7201	12.7080
	stelfi	0.1335	0.3203	2.0105	12.9649
50	DEoptim	0.2043	0.0251	1.3105	25.6803
	stelfi	0.2363	0.0215	1.4014	25.7833
61	DEoptim	0.1288	0.2503	2.0200	20.2909
	stelfi	0.1426	0.2598	1.9198	20.3283
64	DEoptim	0.1190	0.0395	0.8555	18.4621
	stelfi	0.1166	0.1432	1.0443	18.5321
65	DEoptim	0.1406	0.1828	1.0670	16.6206
	stelfi	0.1854	0.1729	0.8504	16.8644
67	DEoptim	0.1412	0.1670	0.5997	18.0476
	stelfi	0.1401	0.1769	0.3643	18.2530
71	DEoptim	0.1365	0.3350	2.3624	22.9661
	stelfi	0.1568	0.0643	1.6912	23.0758
73	DEoptim	0.2079	0.0083	2.8004	25.6861
	stelfi	0.2335	0.0000	655.4096	25.7539
80	DEoptim	0.1883	0.2966	1.1061	21.0455
	stelfi	0.3143	0.0850	1.0178	21.7088
82	DEoptim	0.1572	0.2720	2.1548	11.1444
	stelfi	0.2410	0.0000	67.7195	11.4757
84	DEoptim	0.1414	0.0260	0.1448	16.7163
	stelfi	0.1315	0.0703	0.0703	17.3099

Cuadro 7.3: Comparación de estimaciones entre `DEoptim` y `stelfi` para Nikola Vucevic.

Match ID	**Método**	$\widehat{\mu}$	$\widehat{\theta}$	$\widehat{\phi}$	− Log-verosimilitud
7	DEoptim	0.0589	0.0304	0.4964	11.3063
	stelfi	0.0570	0.1473	0.4148	11.5133
18	DEoptim	0.0903	0.9288	3.4205	15.9319
	stelfi	0.0940	0.2802	1.7953	16.0214
32	DEoptim	0.0299	0.2616	0.4979	10.2381
	stelfi	0.0337	0.3164	0.3164	10.6633
36	DEoptim	0.0544	0.2244	0.7042	13.2781
	stelfi	0.0639	0.3679	0.5043	13.9050
40	DEoptim	0.0252	0.2045	0.6461	7.7984
	stelfi	0.0268	0.5341	0.5341	8.4659
44	DEoptim	0.1100	0.0569	0.4732	18.4231
	stelfi	0.1159	0.1140	0.2669	18.8975
45	DEoptim	0.0556	0.2128	0.6573	13.3663
	stelfi	0.0626	0.3191	0.4431	13.9322
46	DEoptim	0.0642	0.1929	0.6548	13.7453
	stelfi	0.0732	0.1870	0.4567	13.8925
53	DEoptim	0.0695	0.2452	2.3036	13.5735
	stelfi	0.0693	1.1680	3.4309	14.4894
57	DEoptim	0.0692	**1.2311**	2.7445	14.6682
	stelfi	0.0718	0.9398	2.2763	14.7002
58	DEoptim	0.1477	0.3328	1.4979	23.5128
	stelfi	0.1621	0.3248	1.2552	23.5868
59	DEoptim	0.1604	0.1003	2.2203	11.1573
	stelfi	0.2474	0.0000	10.2378	11.5245
61	DEoptim	0.0417	0.0943	0.0625	16.6525
	stelfi	0.0441	0.1182	0.1182	16.7026
65	DEoptim	0.0365	0.1055	0.2297	10.8759
	stelfi	0.0374	0.1779	0.1779	11.1872
68	DEoptim	0.0743	0.1433	1.3091	13.8328
	stelfi	0.0986	0.1918	1.3398	14.0072
69	DEoptim	0.0577	0.0435	0.5983	11.2954
	stelfi	0.0594	0.1979	0.5006	11.6269
74	DEoptim	0.0558	0.4315	0.8071	14.6287
	stelfi	0.0656	0.3936	0.6798	14.7016
77	DEoptim	0.0746	0.0509	0.5393	13.9064
	stelfi	0.0736	0.2284	0.5042	14.3275
80	DEoptim	0.1112	0.0420	0.4049	18.4442
	stelfi	0.1138	0.1019	0.3203	18.6639
83	DEoptim	0.1100	0.6118	1.4309	10.5406
	stelfi	0.1064	0.2306	0.2306	11.0901

Cuadro 7.4: Comparación de estimaciones entre `DEoptim` y `stelfi` para Coby White.

Bibliografía

Albert, J., Glickman, M. E., Swartz, T. B., and Koning, R. H. (2017). *Handbook of statistical methods and analyses in sports*. Crc Press.

Bocskocsky, A., Ezekowitz, J., and Stein, C. (2014). The hot hand: A new approach to an old 'fallacy'. In *8th Annual MIT Sloan Sports Analytics Conference*, pages 1–10.

Briz-Redón, Á. and Mateu, J. (2024). Point process modeling through a mixture of homogeneous and self-exciting processes. *Statistica Neerlandica*, 78(4):600–616.

Daley, D. J. and Vere-Jones, D. (2006). *An introduction to the theory of point processes: volume I: elementary theory and methods*. Springer Science & Business Media.

Fox, E. W., Short, M. B., Schoenberg, F. P., Coronges, K. D., and Bertozzi, A. L. (2016). Modeling e-mail networks and inferring leadership using self-exciting point processes. *Journal of the American Statistical Association*, 111(514):564–584.

Gilovich, T., Vallone, R., and Tversky, A. (1985). The hot hand in basketball: On the misperception of random sequences. *Cognitive psychology*, 17(3):295–314.

Green, B., Horel, T., and Papachristos, A. V. (2017). Modeling contagion through social networks to explain and predict gunshot violence in chicago, 2006 to 2014. *JAMA internal medicine*, 177(3):326–333.

Jones-Todd, C. M. and van Helsdingen, A. B. (2024). stelfi: An R package for fitting Hawkes and log-Gaussian Cox point process models. *Ecology and Evolution*, 14(2):e11005.

Kulkarni, V. G. (2011). *Introduction to modeling and analysis of stochastic systems*, volume 1. Springer.

Meyer, S., Elias, J., and Höhle, M. (2012). A space–time conditional intensity model for invasive meningococcal disease occurrence. *Biometrics*, 68(2):607–616.

Mohler, G. (2014). Marked point process hotspot maps for homicide and gun crime prediction in chicago. *International Journal of Forecasting*, 30(3):491–497.

Mohler, G. O., Short, M. B., Brantingham, P. J., Schoenberg, F. P., and Tita, G. E. (2011). Self-exciting point process modeling of crime. *Journal of the american statistical association*, 106(493):100–108.

Mullen, K. M., Ardia, D., Gil, D. L., Windover, D., and Cline, J. (2011). Deoptim: An r package for global optimization by differential evolution. *Journal of Statistical Software*, 40:1–26.

Ogata, Y. (1998). Space-time point-process models for earthquake occurrences. *Annals of the Institute of Statistical Mathematics*, 50:379–402.

Reinhart, A. (2018). A review of self-exciting spatio-temporal point processes and their applications. *Statistical Science*, 33(3):299–318.

Schoenberg, F. P., Hoffmann, M., and Harrigan, R. J. (2019). A recursive point process model for infectious diseases. *Annals of the Institute of Statistical Mathematics*, 71:1271–1287.

Sun, Y. and Wang, H. (2012). The "hot hand" revisited: A nonstationarity argument. *PsyCh Journal*, 1(1):28–39.

Zhuang, J., Ogata, Y., and Vere-Jones, D. (2002). Stochastic declustering of space-time earthquake occurrences. *Journal of the American Statistical Association*, 97(458):369–380.